2. *Sistemas de análisis de la información*

A.D.G.

Donde estamos

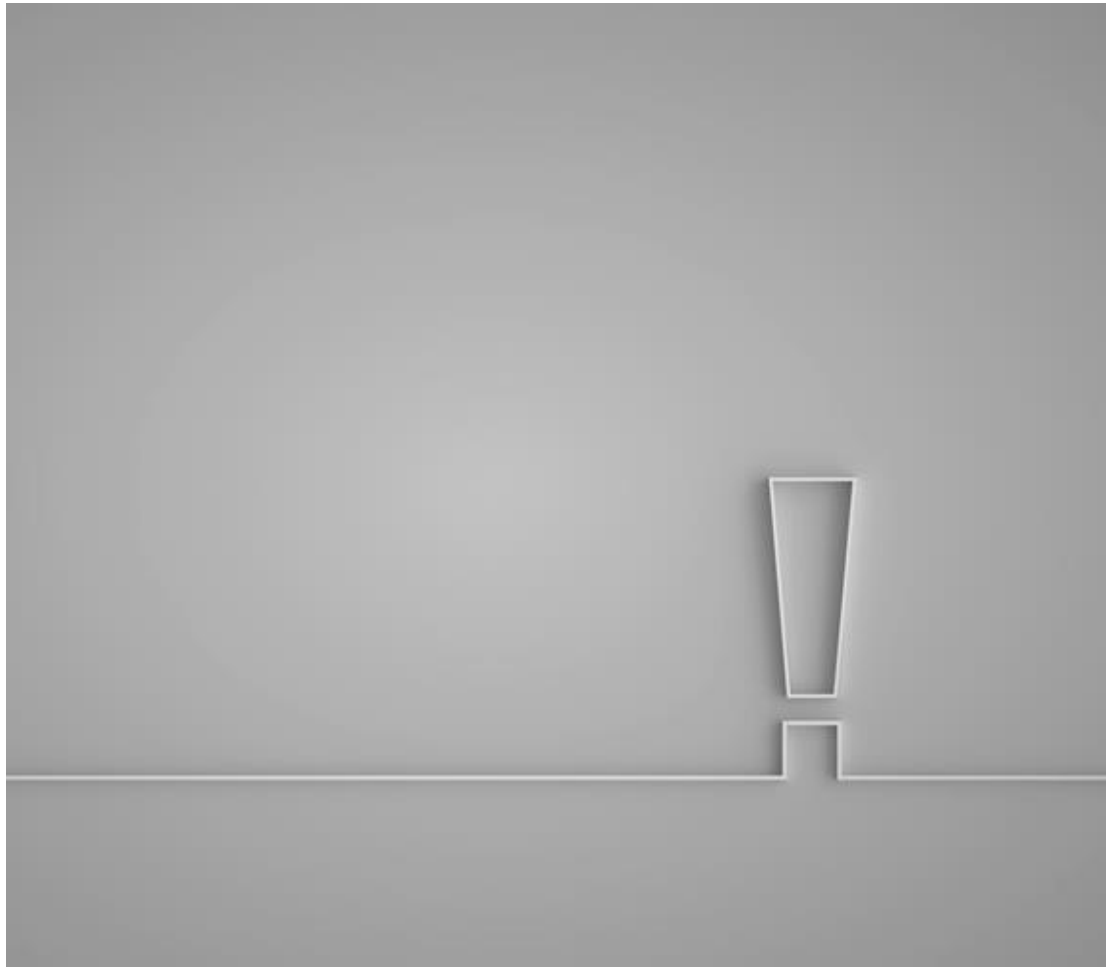

- Estamos en *(IFCD0211 > MF0488_3: Consulta y manipulación de información contenida en gestores de datos (210 horas)*
- *UF2215: HERRAMIENTAS DE LOS SISTEMAS GESTORES DE BASES DE DATOS. PASARELAS Y MEDIOS DE CONEXIÓN (70 horas)*

Carpeta compartida del curso

1. Acceso a la carpeta en la nube: https://drive.google.com/open?id=1Th1QQE3fjW6BE04bhKI957HFzdzfxY8h&usp=drive_fs
2. Todo el contenido estará en esa carpeta.

2. Sistemas de análisis de la información

1. – Minería de datos.
2. – OLAP.
3. – Dashboard/scorecard.
4. – Herramientas:
    1. – Administración.
    2. – Migración .
    3. – ETL.
    4. – Información estadística.

1. Minería de datos

Los “sistemas de análisis de la información” que citas forman parte del ecosistema de Business Intelligence y se apoyan en herramientas de administración, migración, ETL y análisis estadístico.

Minería de datos

La **minería de datos** (data mining) es el conjunto de técnicas y procesos que permiten descubrir patrones, correlaciones, reglas y modelos predictivos en grandes volúmenes de datos.
Se apoya en algoritmos de estadística, machine learning y modelos matemáticos (árboles de decisión, clustering, redes neuronales, reglas de asociación, etc.).

Usos típicos:

Segmentación de clientes (clústeres según comportamiento de compra).

Detección de fraude (identificación de transacciones anómalas).

Predicción (ventas futuras, riesgo de impago, abandono de clientes).

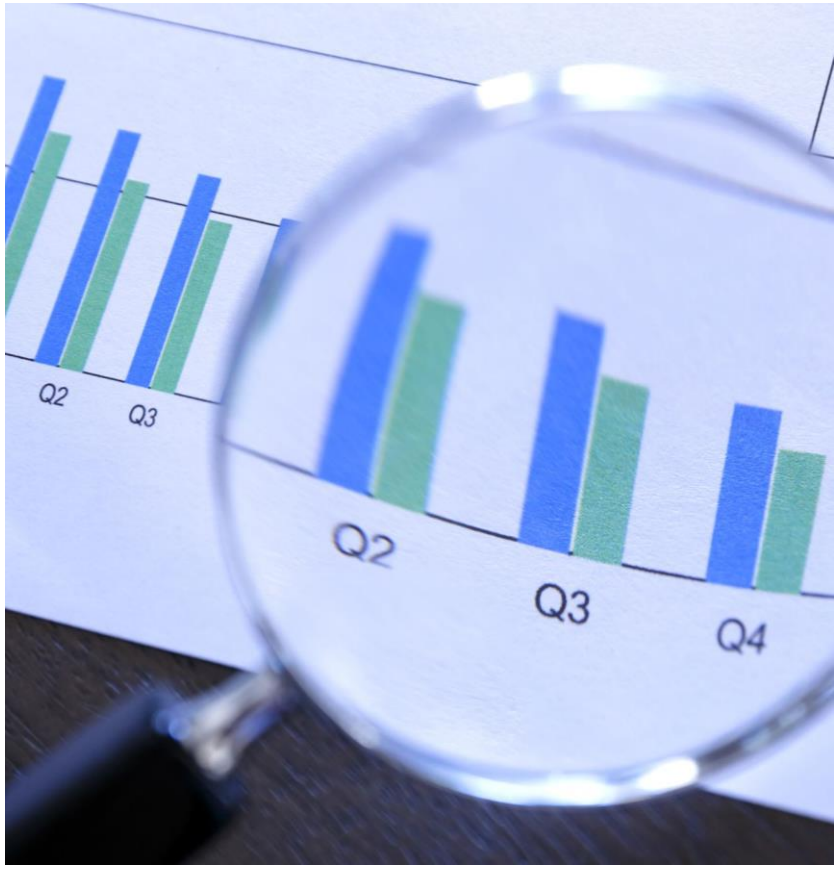

1. Minería de datos

A efectos didácticos, puedes pensar en dashboards de minería de datos como “pantallas” que explotan modelos o patrones ya descubiertos (segmentaciones, modelos de scoring, detección de anomalías, etc.) y los convierten en decisiones accionables.

1. Dashboard de churn (abandono de clientes)

Objetivo: visualizar el resultado de un modelo de predicción de churn y priorizar acciones de retención.

Componentes típicos:

KPI globales: tasa de churn actual, churn previsto a 30/60/90 días, ingresos en riesgo.

Gráfico de barras: churn por segmento (plan, país, canal de adquisición, antigüedad).

Tabla detallada: lista de clientes ordenados por “risk score”, ingreso anual (ARR) y fecha de renovación, con semáforos verde/amarillo/rojo según umbrales del modelo.

Filtros: por gestor de cuenta, región, tipo de producto, etc.

Uso de minería de datos:

Un modelo supervisado (p. ej. regresión logística, árbol de decisión, etc) calcula la probabilidad de churn de cada cliente.

El dashboard traduce ese score en **niveles de riesgo** y muestra factores clave que impulsan el riesgo (caída de uso, tickets de soporte, NPS bajo).

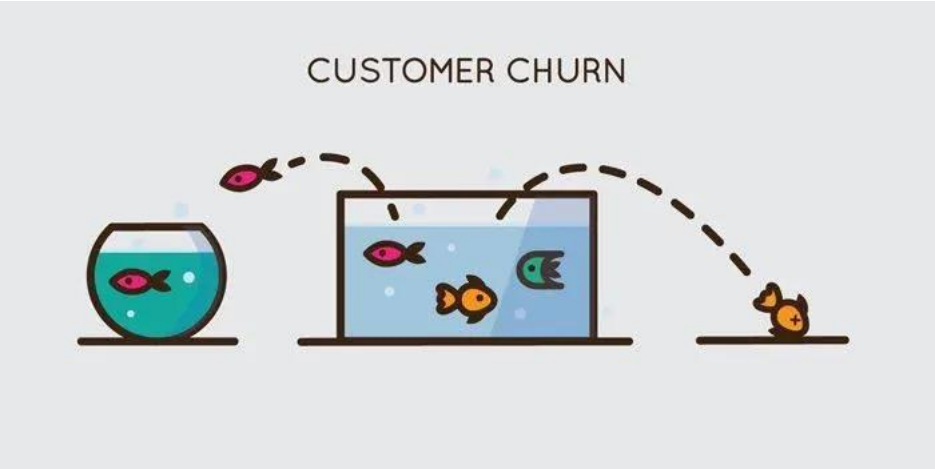

1. Minería de datos

En 2025, el operador **Digi volvió a liderar la captación** de portabilidades en España: logró un récord de casi **994.000 líneas netas ganadas** (784.000 móviles y 210.000 de banda ancha). En cambio, empresas como Vodafone perdieron decenas de miles de clientes en ese mismo periodo (por ejemplo, 220.000 líneas móviles perdidas netas).

Qué significan estos datos para churn

Churn por portabilidad
La portabilidad es una forma directa de medir churn: cuando un cliente cambia de operador, se considera una baja de la compañía original.

Ejemplo de cálculo simplificado (conceptual):
Si Vodafone tenía 10 millones de clientes y perdió 58.000 por portabilidad neta este trimestre, su churn trimestral sería:

$$Churn \approx \frac{58\,000}{10\,000\,000} \times 100 = 0{,}58\%$$

Este tipo de cifras se calcula de forma más detallada por las empresas y reguladores, pero el principio es el mismo: clientes que se van / clientes que había.

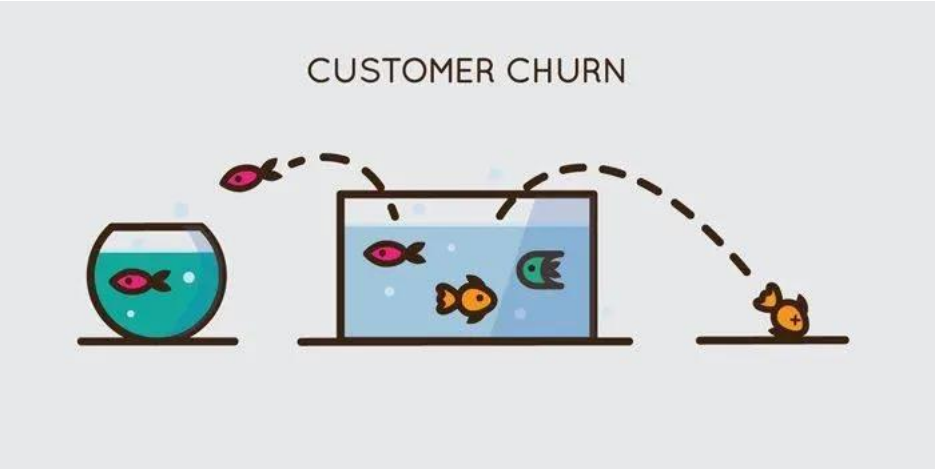

Ejemplo

Dashboard básico de churn

Ideal para dirección o gerencia.

Qué muestra:

- Tasa de churn total (%)
- Clientes perdidos este mes
- Clientes nuevos vs perdidos
- Evolución del churn (últimos 12 meses)
- Ingresos perdidos por abandono

Visualizaciones típicas:

KPI grande: **Churn Rate = 5,2%**

Gráfico de líneas → evolución mensual

Tarjetas KPI:

Clientes activos
Clientes cancelados
MRR perdido (ingresos mensuales recurrentes)

Ejemplo visual:

Clientes activos: 12.450
Clientes perdidos (mes): 320
Churn rate: 5,2%
Ingresos perdidos: 18.000 €

Churn = (Clientes perdidos/Clientes al inicio del mes)×100

Concepto	Clientes
Inicio del mes	6.154
Nuevos clientes	+6.616
Perdidos	−320
Final del mes	12.450

Ejercicio

1. Clientes al inicio del mes
Calcula cuántos clientes había al principio del mes.

2. Churn rate
Calcula el porcentaje de clientes que abandonaron el gimnasio este mes.

Fórmula:

$$Churn = \frac{Clientes\ perdidos}{Clientes\ al\ inicio\ delmes} \times 100$$

3. MRR perdido
Calcula cuánto dinero mensual ha dejado de ingresar el gimnasio por los clientes que se fueron.

Fórmula:

$$MRR\ perdido = Clientes\ perdidos \times Pago\ mensual$$

4. Ingresos perdidos totales (12 meses)
Calcula cuánto dinero dejarán de recibir si esos clientes se hubieran quedado 12 meses más.

Fórmula:

$$Ingresos\ perdidos = MRR\ perdido \times 12$$

Ejercicio (solución)

1. Clientes al inicio del mes

$$Clientes\ inicio = Clientes\ finales + Clientes\ perdidos$$
$$Clientes\ inicio = 500 + 25 = 525$$

2. Churn rate

$$Churn = \frac{Clientes\ perdidos}{Clientes\ inicio} \times 100$$
$$Churn = \frac{25}{525} \times 100 \approx 4{,}76\%$$

Interpretación: **aproximadamente 5 de cada 100 clientes se fueron este mes.**

3. MRR perdido

$$MRR\ perdido = Clientes\ perdidos \times Pago\ mensual$$
$$MRR\ perdido = 25 \times 20€ = 500€/mes$$

4. Ingresos perdidos totales (12 meses)

$$Ingresos\ perdidos = MRR\ perdido \times 12$$
$$Ingresos\ perdidos = 500€ \times 12 = 6.000€$$

1. Minería de datos

2. Dashboard de segmentación de clientes (clustering)

Objetivo: explotar un modelo de clustering (k-means, DBSCAN, etc.) que ha segmentado clientes por comportamiento o valor.

Componentes típicos:

Gráfico de dispersión: clientes en dos dimensiones derivadas (por ejemplo, score de valor y score de actividad) coloreados por clúster.

Tarjetas por segmento: tamaño del segmento, facturación total, ticket medio, churn promedio.

Perfil del segmento: barras que comparan variables clave (frecuencia de compra, canales usados, margen, uso de features) entre clúster seleccionado y promedio global.

Filtros: seleccionar clúster y ver lista de clientes dentro de él con detalles.

Uso de minería de datos:

El modelo de clustering agrupa clientes según variables de comportamiento.

El dashboard permite interpretar cada segmento (p. ej. “alto valor–alta fidelidad”, “precio-sensibles”, “nuevos de alto potencial”) y decidir campañas específicas.

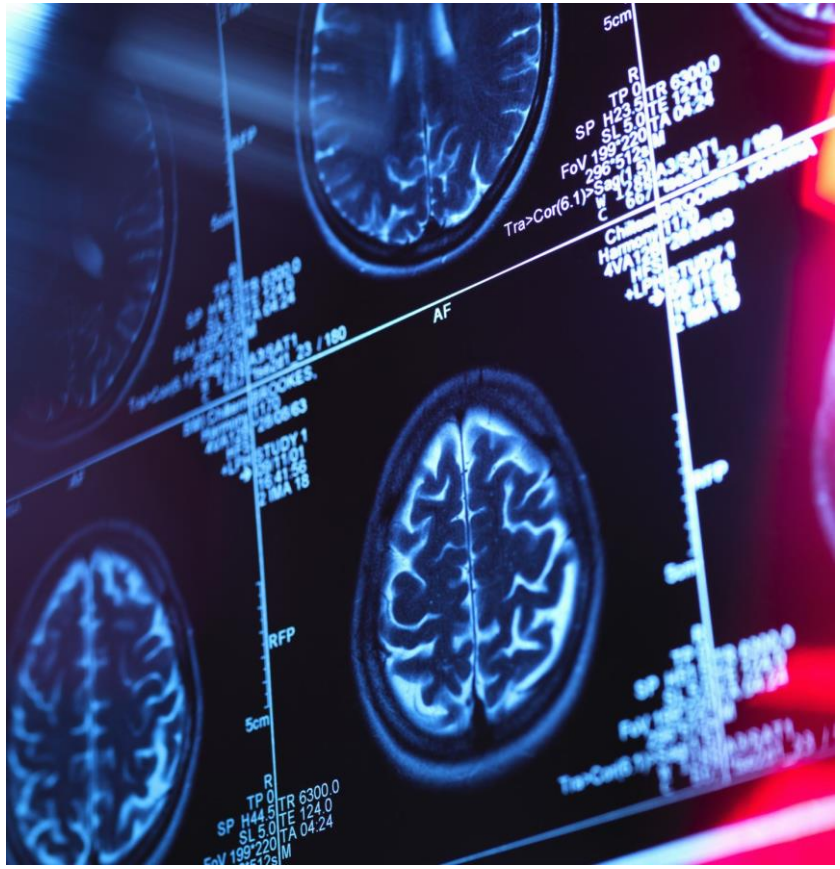

1. Minería de datos

Un **Dashboard de segmentación de clientes** es la herramienta clave para transformar datos brutos en estrategias de marketing personalizadas. El objetivo principal es visualizar cómo se agrupan tus clientes según su comportamiento o perfil.

1. La Visualización Estrella: El Scatter Plot (Clustering)

La pieza central de este dashboard suele ser un gráfico de dispersión (Scatter Plot) donde cada punto es un cliente.

Ejes comunes: Frecuencia de compra (X) vs. Gasto Total (Y).

Colores: Cada color representa un "Cluster" o segmento (ej. VIP, Clientes en Riesgo, Nuevos).

Interactividad: Al pasar el ratón, deberías ver el ID del cliente o su perfil básico.

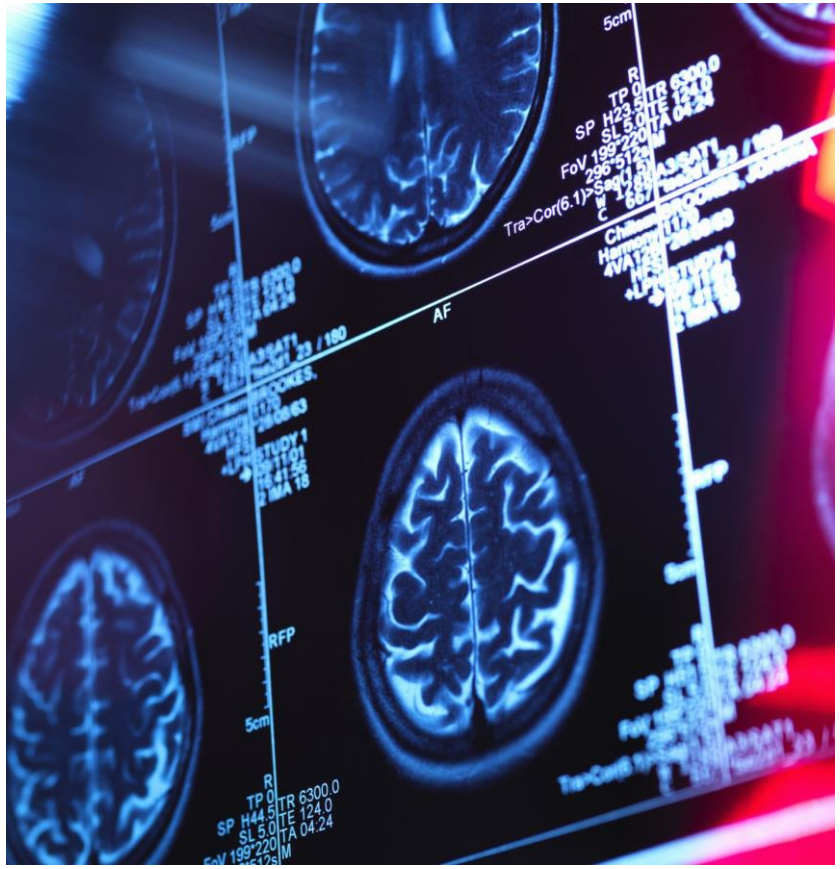

Ejercicio: Crear un Dashboard de Segmentación de Clientes en Google Analytics

Objetivo

Aprender a identificar diferentes segmentos de clientes según comportamiento, adquisición y características demográficas, y visualizarlos en un Dashboard interactivo.

Requisitos

Acceso a la **cuenta demo de Google Analytics**: https://analytics.google.com/analytics/web/?utm_source=demoaccount&utm_medium=demoaccount&utm_campaign=demoaccount#/a54516992p213025502/reports/intelligenthome

Conceptos básicos de métricas de GA: usuarios, sesiones, conversiones, tasa de rebote.

Parte 1: Acceso y exploración

Ingresa a la cuenta demo de GA4 y selecciona la propiedad **Google Merchandise Store GA4**.

Explora los informes principales en **Informes → Ciclo de vida**:

- **Adquisición → Visión general del usuario**
- **Compromiso → Eventos**
- **Monetización → Compras de productos**

Mini-desafío:
Identifica cuál es el canal que trae más usuarios nuevos y cuál tiene mejor tasa de conversión.

Ejercicio: Crear un Dashboard de Segmentación de Clientes en Google Analytics

Parte 2: Crear segmentos de clientes

En GA4 usamos **segmentos dentro de una Exploración**:

Ve a **Explorar** en el menú de la izquierda.

Crea una **Exploración en blanco**.

En la columna de **Segmentos** (a la izquierda), haz clic en **“+”** y crea los siguientes segmentos:

- **Clientes nuevos** → condición: Primera sesión = sí
- **Clientes recurrentes** → condición: Primera sesión = no
- **Compradores frecuentes** → condición: Compras de productos ≥ 3
- **Usuarios con carrito abandonado** → condición: Evento "add_to_cart" sin evento "purchase"

Ejercicio: Crear un Dashboard de Segmentación de Clientes en Google Analytics

Parte 3: Crear el Dashboard en GA4

Dentro de tu **Exploración en blanco**, agrega **tablas y gráficos**:

- **Gráfico de barras**: Usuarios por segmento
- **Tabla**: Ingresos y transacciones por segmento y canal
- **Gráfico de línea**: Sesiones promedio por segmento
- **Indicadores**: Tasa de conversión por segmento

Ajusta filtros según tus segmentos. Por ejemplo, si quieres ver solo **clientes recurrentes**, filtra ese segmento en todos los widgets.

Parte 4: Análisis e interpretación

Responde estas pregunta:

¿Qué segmento aporta más ingresos al negocio?

¿Qué segmento tiene mayor tasa de rebote y qué podría indicar?

Si quisieras mejorar la conversión, ¿en qué segmento te enfocarías y por qué?

¿Qué insights estratégicos puedes extraer sobre los clientes según su comportamiento y frecuencia de compra?

1. Minería de datos

3. Dashboard de detección de anomalías / fraude

Objetivo: monitorizar resultados de modelos de detección de anomalías o scoring de fraude para tarjetas, préstamos, transacciones online, etc.

Componentes típicos:

KPI: número de transacciones marcadas como sospechosas hoy, importe total en riesgo, % de falsos positivos detectados por revisión manual.

Gráfico de línea: evolución diaria/semanal de alertas de fraude vs total de operaciones, con bandas que señalan desviaciones anómalas.

Mapa o heatmap: concentración geográfica de transacciones sospechosas.

Tabla de casos: lista de operaciones con “fraud score”, tipo de anomalía detectada, resultado de la revisión (confirmado, descartado, pendiente).

Uso de minería de datos:

Modelos no supervisados (p. ej. Isolation Forest, LOF) o supervisados (árboles, redes neuronales) calculan un score de anomalía.

El dashboard sirve para priorizar investigaciones, ajustar umbrales y evaluar la calidad del modelo.

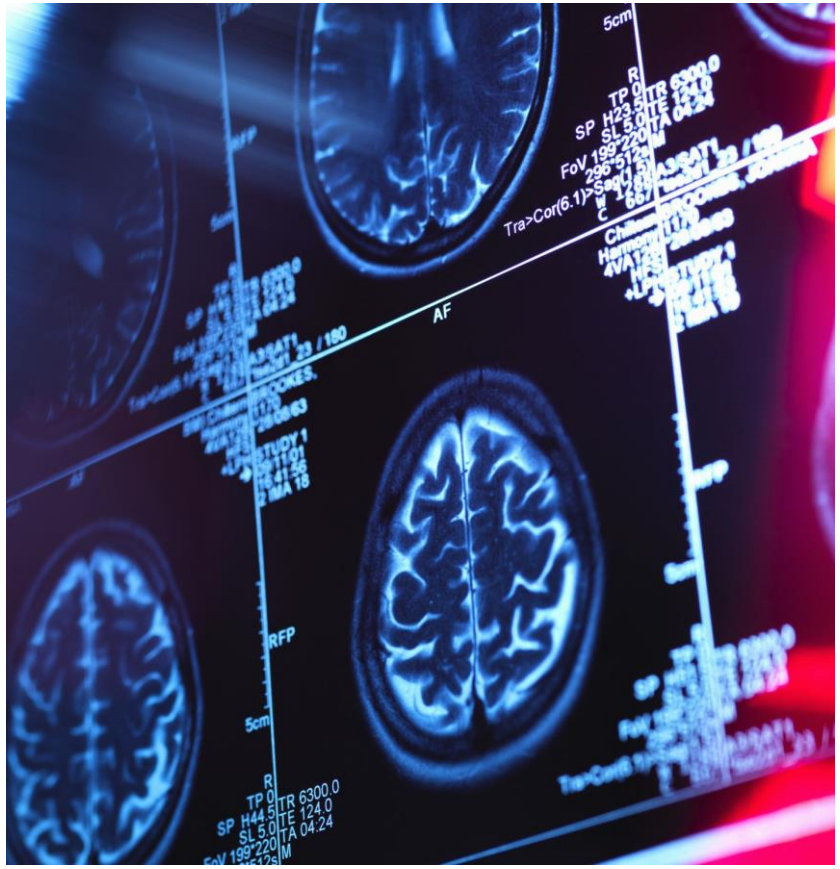

Ejemplo: Dashboard de detección de anomalías / fraude

KPI	Valor hoy	Interpretación
Transacciones sospechosas	**1.842**	Detectadas por el modelo
Importe en riesgo	**€312.450**	Dinero potencialmente fraudulento
% falsos positivos	**18%**	Alertas que NO eran fraude
Fraudes confirmados	**126**	Tras revisión humana
⏱️ Tiempo medio revisión	**9 min**	Eficiencia del equipo

Objetivo del dashboard

Monitorizar en tiempo real las transacciones con tarjeta para detectar posibles fraudes y ayudar al equipo antifraude a decidir **qué casos revisar primero**.

Imagina un banco ficticio: **FinBank**.

Cada día procesa **250.000 transacciones online**.

1. KPI principales (parte superior del dashboard)

Zona tipo “panel de control” con indicadores grandes.

Ejemplo práctico:
Si el % de falsos positivos sube mucho → el modelo está siendo demasiado estricto.

Ejemplo: Gráfico de línea — Evolución del fraude

Gráfico temporal (últimos 30 días):

Línea azul → total de transacciones diarias

Línea roja → alertas de fraude

Banda sombreada → rango normal esperado

Ejemplo de lectura:

Día	Alertas	
Lunes	1.200	
Martes	1.350	
Miércoles	1.400	
Jueves	2.900	← anomalía
Viernes	1.300	

El jueves aparece un pico fuera del rango normal.

Posible causa: ataque automatizado, filtración de tarjetas, campaña fraudulenta, el dashboard lo resalta automáticamente.

Ejercicio

ID	País	Importe (€)	Fraud Score	Resultado revisión
T001	España	25	0.20	Descartado
T002	México	950	0.92	Pendiente
T003	España	40	0.35	Descartado
T004	Japón	1.200	0.97	Confirmado
T005	España	15	0.10	Descartado

Un banco analiza las siguientes transacciones detectadas por su modelo antifraude:

El **Fraud Score** va de 0 a 1:

cercano a 0 → normal

cercano a 1 → muy sospechoso

Preguntas

KPI básicos

Responde:

a) ¿Cuántas transacciones están marcadas como sospechosas (score > 0.80)?
b) ¿Cuál es el importe total en riesgo (solo sospechosas)?

1. Minería de datos

4. Dashboard de recomendación de productos / next best offer

Objetivo: aprovechar un sistema de recomendación (filtrado colaborativo, reglas de asociación tipo Apriori, etc.) para guiar ventas cruzadas o upselling.

Componentes típicos:

KPI: tasa de aceptación de recomendaciones, ingresos por ventas cruzadas, clics en recomendaciones.

Gráfico de barras: productos más recomendados vs más aceptados (efectividad de las reglas de asociación).

Vista por cliente: ficha que muestra “productos recomendados”, probabilidad estimada de compra y reglas que justifican la recomendación (por ejemplo, “clientes que compraron X también compran Y”).

Filtros: canal (web, tienda, call center), campaña, segmento.

Uso de minería de datos:

Reglas de asociación o modelos de recomendación generan listas ordenadas de productos por probabilidad o afinidad.

El dashboard muestra rendimiento del motor de recomendación y permite probar distintas estrategias (por ejemplo, distintos sets de reglas o modelos).

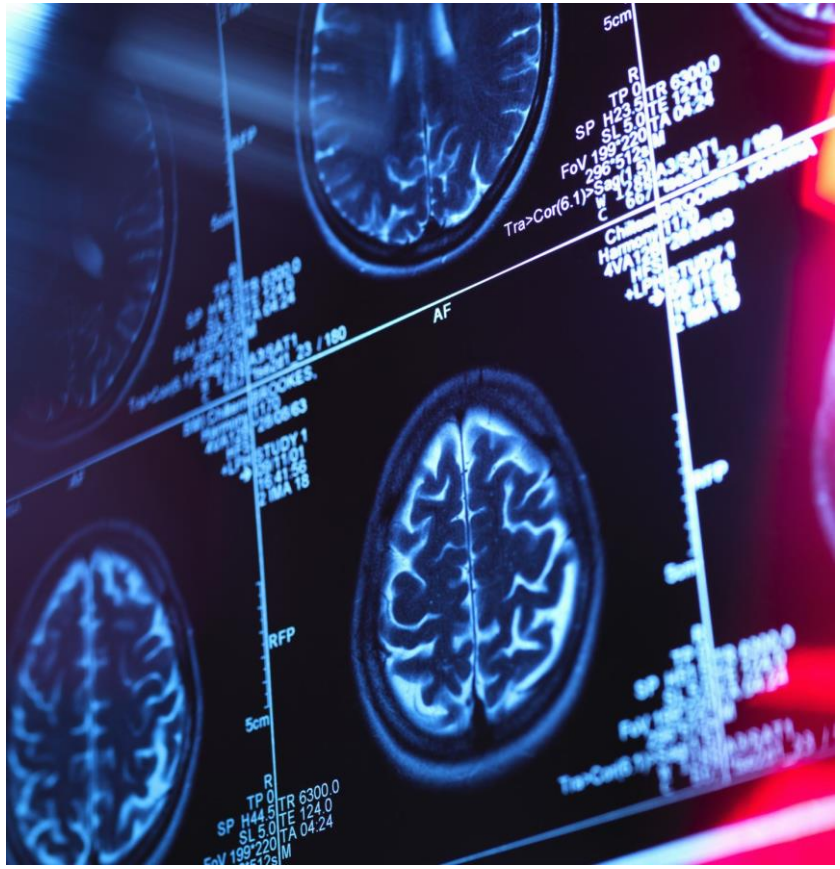

Ejemplo: Dashboard de recomendación de productos (Next Best Offer)

Producto	Veces recomendado	Veces comprado
Funda móvil	500	210
Auriculares	420	180
Cargador rápido	300	95

Objetivo

Ayudar a una tienda online a recomendar productos que el cliente probablemente comprará para aumentar las ventas.

Ejemplo: tienda online de tecnología.

Componentes del dashboard

KPI principales

Tasa de aceptación: **22%** (clientes que compran lo recomendado)

Ventas cruzadas generadas: **8.500 €**

Clics en recomendaciones: **1.240**

Gráfico de barras

Comparación:

Sirve para ver qué recomendaciones funcionan mejor.

1. Minería de datos

5. Dashboard de calidad de datos para minería

Objetivo: antes o durante la minería de datos, supervisar la calidad de la información que alimenta los modelos.

Componentes típicos:

KPI: porcentaje de valores faltantes por tabla o campo clave, número de registros duplicados, variables con alta cardinalidad inesperada.

Gráficos:

- Barras para % de missing por variable.
- Boxplots o violín para detectar outliers extremos en variables numéricas.

Timeline: evolución diaria/semanal de incidencias de calidad (rotura de pipelines, cambios de esquema, etc.).

Uso de minería de datos:

Aunque aquí no se explota un modelo “predictivo”, sí se usan análisis estadísticos y de outliers que son parte del proceso de data mining.

El dashboard permite decidir si los datos están listos para entrenar o desplegar modelos y dónde aplicar reglas de limpieza adicionales.

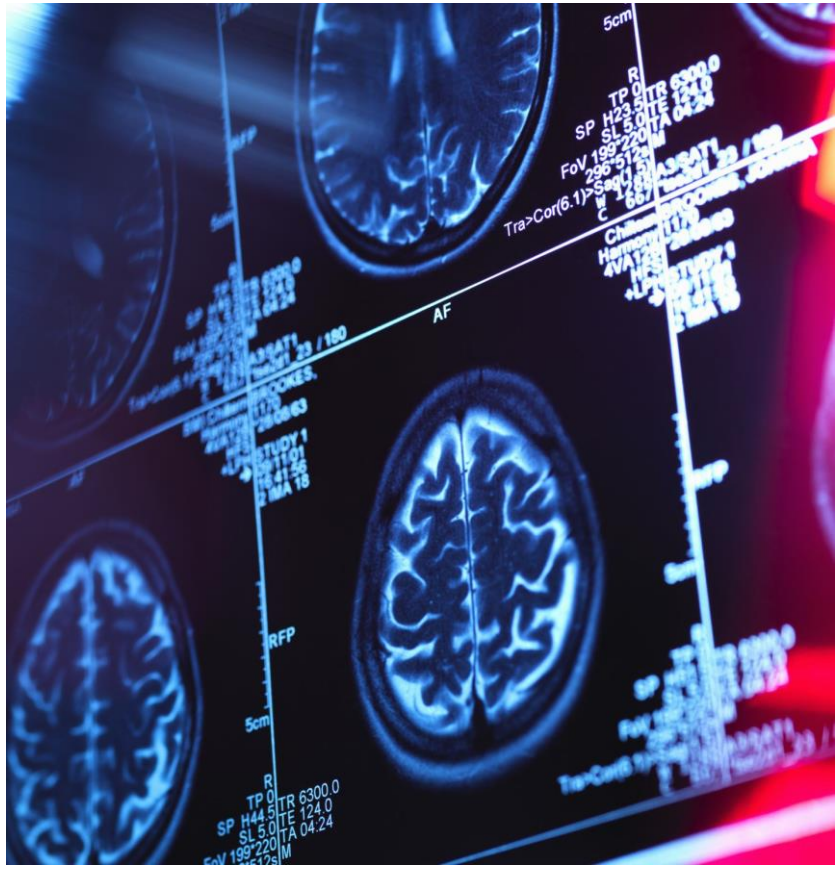

1. Minería de datos

¿Qué es la detección del fraude con IA en el sector bancario?

Dentro del sector bancario y de servicios financieros, la inteligencia artificial (IA) para la detección del fraude se refiere a la implementación de algoritmos de machine learning (ML) para mitigar las actividades fraudulentas.

Al analizar conjuntos de datos grandes, los modelos de IA pueden aprender a reconocer la diferencia entre actividades sospechosas y transacciones legítimas, y pueden ayudar a identificar posibles riesgos de fraude para prevenir delitos financieros, incluso detectando tendencias que un agente humano podría pasar por alto.

Las instituciones financieras integran cada vez más soluciones de IA en los flujos de trabajo nuevos y existentes para mejorar la toma de decisiones, la prevención del fraude y la gestión del riesgo. Los modelos de machine learning con IA entrenados a partir de datos históricos pueden utilizar el reconocimiento de patrones para detectar y bloquear automáticamente la ejecución de posibles transacciones fraudulentas. También pueden requerir que los agentes humanos completen pasos de autenticación adicionales para verificar una transacción sospechosa. La tecnología de IA también puede utilizar el análisis predictivo para estimar qué tipos de transacciones futuras podría realizar una persona, y puede reconocer si un nuevo tipo de transacción o comportamiento transaccional es inusual.

1. Minería de datos

De esta manera, la tecnología financiera de la IA puede ayudar a proteger a las personas de las pérdidas financieras que se derivan de varios tipos de fraude, incluidas las estafas de phishing, el fraude de pagos, el fraude con tarjetas de crédito y otros tipos de fraude bancario.

Los sistemas de detección del fraude con IA no son perfectos y algunos falsos positivos pueden afectar negativamente la experiencia del cliente. Pero evitar que los estafadores cometan delitos financieros que van desde cargos no autorizados hasta lavado de dinero es fundamental para garantizar la seguridad de las cuentas de los clientes y mantener el cumplimiento normativo de las instituciones financieras.

A medida que continúan los avances en la tecnología de IA, tanto los proveedores de prevención del fraude impulsado por IA como las principales instituciones financieras apuestan por que la IA se convierta en una herramienta aún más valiosa para prevenir los intentos de fraude y mitigar los riesgos de fraude.

1. Minería de datos

Cómo se utiliza la IA en la detección del fraude financiero

La tecnología de IA permite a los ordenadores comportarse, aprender, adaptarse, resolver problemas y actuar con autonomía de forma similar a la cognición humana. Aunque los sistemas de IA no son necesariamente tan inteligentes como sus homólogos humanos, cuando operan dentro de sistemas estrictos y basados en reglas, una IA entrenada y centrada en tareas específicas puede igualar o superar a los agentes humanos a velocidades mucho más rápidas y escalas mucho mayores.

Aprendizaje supervisado vs. no supervisado

Los sistemas de IA utilizados en la prevención del fraude bancario están muy ajustados para tareas específicas. Los modelos de IA se entrenan utilizando grandes cantidades de datos cuidadosamente seleccionados a través de un proceso llamado aprendizaje supervisado. Este **método enseña al modelo a reconocer patrones** específicos para tareas específicas.

Por el contrario, el aprendizaje no supervisado permite a los sistemas de IA **extraer conclusiones a partir de datos anteriores** sin materiales de formación dirigidos.

Ejemplo de aprendizaje supervisado

Situación: detectar si un email es spam.

Tenemos datos ya etiquetados:

El modelo **aprende usando respuestas correctas** (ya sabemos cuál es spam).

Objetivo: predecir si un nuevo email será spam o no.

Idea clave:
Hay ejemplos con solución conocida.

Email	Resultado
“Gana dinero rápido”	Spam
“Factura del mes”	No spam
“Oferta exclusiva”	Spam

Ejemplo de aprendizaje no supervisado

Situación: agrupar clientes de una tienda.

Datos sin etiquetas:

El modelo descubre grupos automáticamente:

Grupo 1 → clientes jóvenes que gastan poco

Grupo 2 → clientes mayores que gastan mucho

Nadie le dijo cuáles eran los grupos.

Idea clave:
El modelo encuentra patrones sin respuestas previas.

Cliente	Edad	Gasto mensual
A	22	30€
B	24	35€
C	55	400€

2. OLAP

OLAP (On-Line Analytical Processing) es una tecnología orientada al análisis multidimensional de grandes volúmenes de datos, típicamente almacenados en un data warehouse, para soporte a la decisión y Business Intelligence.

Definición y propósito

OLAP permite hacer consultas analíticas complejas, agregaciones y comparaciones sobre datos históricos sin impactar en los sistemas transaccionales OLTP. Se utiliza en reporting avanzado, cuadros de mando, planificación, presupuestos, análisis de ventas, marketing, finanzas, etc.

Ejemplo: analizar ventas por producto, región, canal y mes, con capacidad de “subir/bajar” nivel de detalle rápidamente.

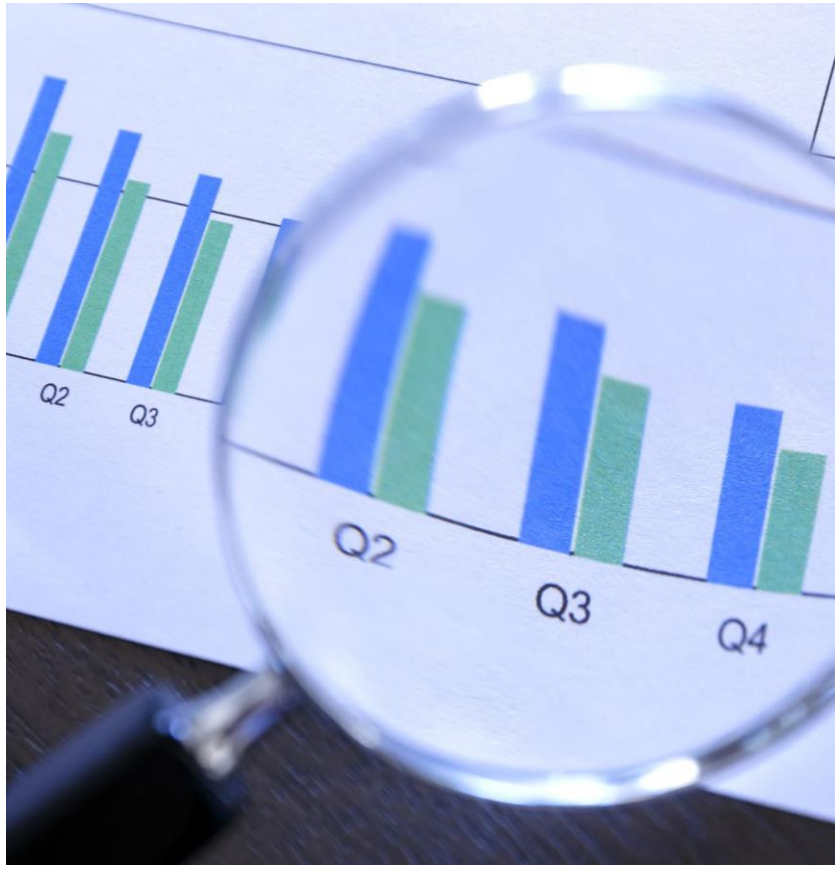

2. OLAP

Modelo multidimensional: cubos, hechos y dimensiones

Un cubo OLAP (o hipercubo) organiza datos en forma multidimensional: cada eje representa una **dimensión** (tiempo, producto, región, cliente, etc.). En el centro están las **medidas** (hechos numéricos): ventas, unidades, costes, beneficio, etc.

Estructura básica:

Tabla de **hechos**: contiene las medidas y claves a las dimensiones (por ejemplo, ventas).

Tablas de **dimensiones**: describen contextos de análisis (dim tiempo con jerarquía año→trimestre→mes→día; dim producto con categoría→subcategoría→producto).

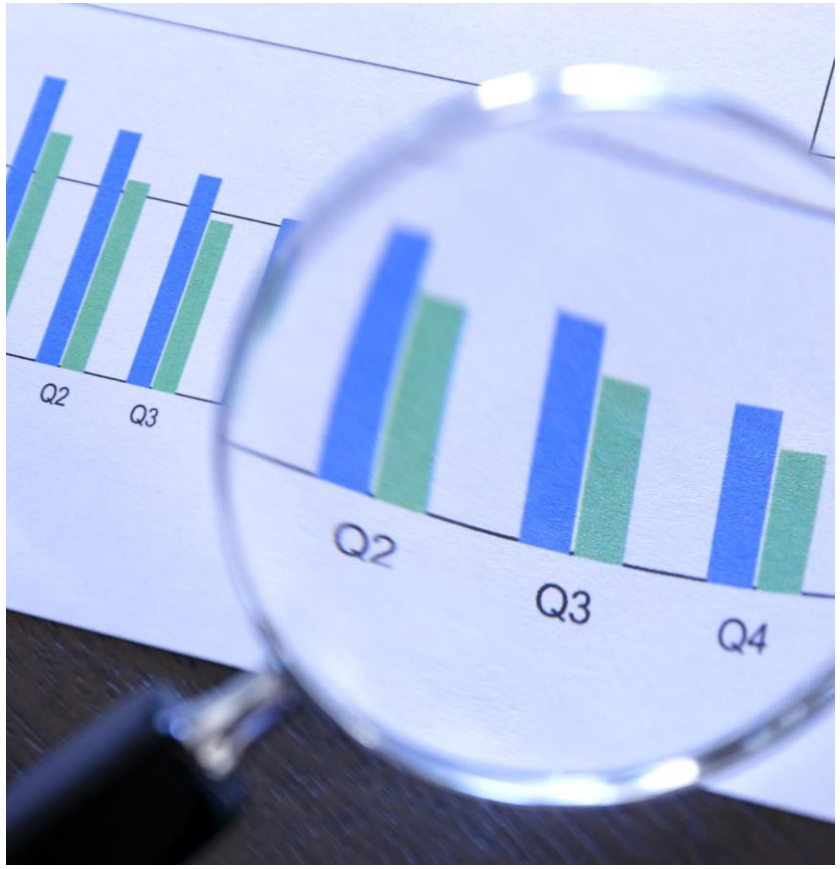

2. OLAP

Operaciones básicas OLAP

Operaciones típicas sobre cubos OLAP:

Roll-up (consolidación/agregación): subir en la jerarquía o agrupar para ver menos detalle (de ventas por ciudad a ventas por país, de día a mes).

Drill-down: bajar al detalle (de país a región a ciudad; de año a trimestre a mes a día).

Slice (corte): fijar un valor en una dimensión y obtener un subcubo (por ejemplo, solo año 2025).

Dice (trocear): filtrar por varios valores/dimensiones, obteniendo un subcubo más específico (por ejemplo, año 2025, productos electrónicos, países ES y PT).

Pivot: girar el cubo, cambiando qué dimensiones se muestran en filas y columnas (similar a una tabla dinámica).

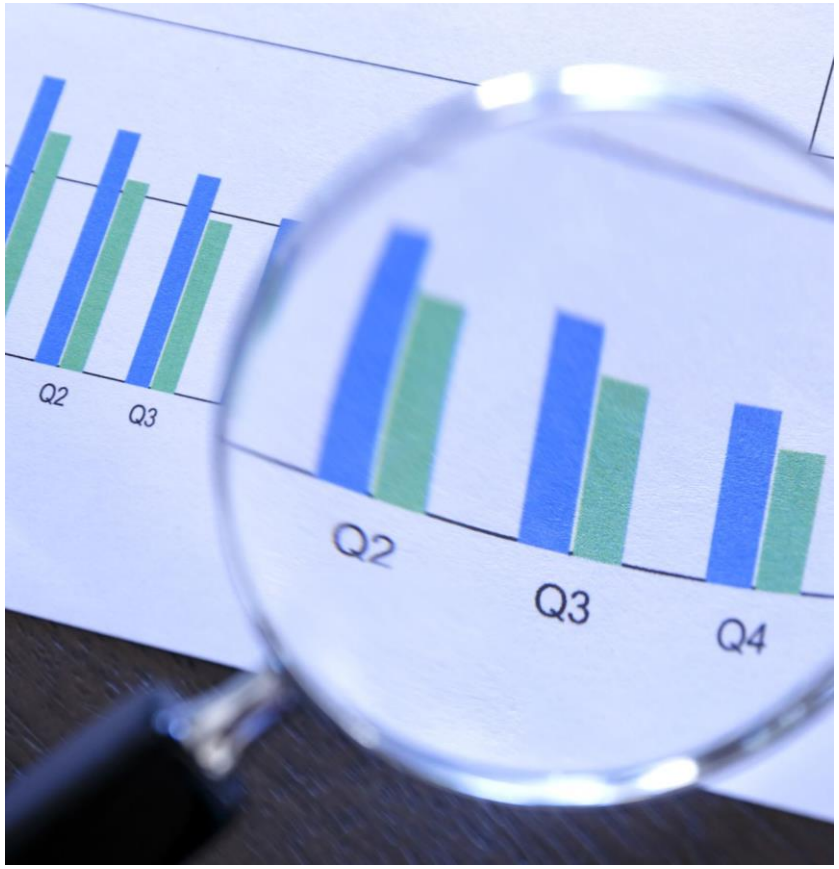

2. OLAP

Tipos de OLAP (visión clásica)

MOLAP (Multidimensional OLAP): datos almacenados en estructuras multidimensionales optimizadas (cubo físico), muy rápido para agregaciones; típico de motores OLAP clásicos.

ROLAP (Relational OLAP): el modelo multidimensional se implementa sobre bases de datos relacionales, usando vistas, agregaciones y SQL; escala bien con grandes volúmenes.

HOLAP (Hybrid OLAP): combina MOLAP y ROLAP, guardando agregados en estructuras multidimensionales y detalle en relacional.

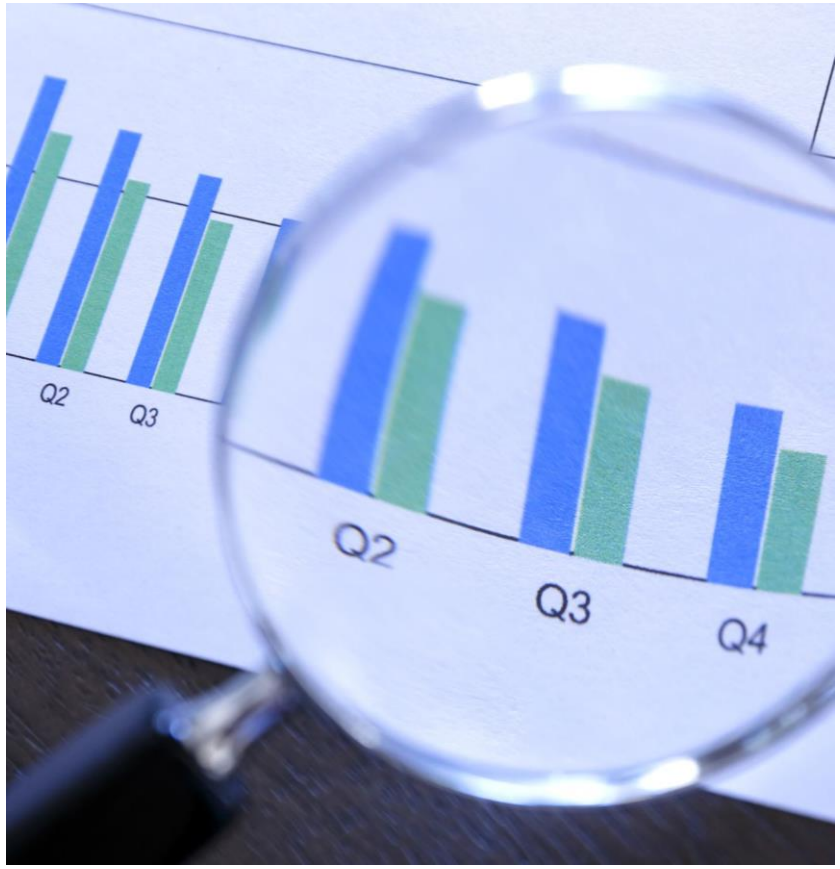

Ejercicio resuelto OLAP con Python

Paso 1: Crear los datos

Copiar este código:

```
import pandas as pd

# Crear datos de ventas
datos = {
    "Año": [2024, 2024, 2024, 2024, 2025, 2025, 2025, 2025],
    "Ciudad": ["Vigo", "Vigo", "Pontevedra", "Pontevedra",
               "Vigo", "Vigo", "Pontevedra", "Pontevedra"],
    "Producto": ["Portátiles", "Tablets", "Portátiles", "Tablets",
                 "Portátiles", "Tablets", "Portátiles", "Tablets"],
    "Ventas": [5000, 3000, 4000, 2500, 6000, 3500, 4500, 3000]
}

df = pd.DataFrame(datos)

print(df)
```

Esto crea una pequeña tabla de ventas.

Paso 2: Operaciones OLAP básicas

Slice (ver solo un año)

```
ventas_2025 = df[df["Año"] == 2025]
print(ventas_2025)
```

Muestra solo los datos de 2025.

Dice (filtrar varias condiciones)

```
vigo_portatiles = df[(df["Ciudad"] == "Vigo") & (df["Producto"] == "Portátiles")]
print(vigo_portatiles)
```

3. Roll-up (resumen por año)

```
total_por_año = df.groupby("Año")["Ventas"].sum()
print(total_por_año)
```

Resume las ventas totales por año.

4. Drill-down (ver detalle)

```
detalle_2025 = df[df["Año"] == 2025].groupby("Ciudad")["Ventas"].sum()
print(detalle_2025)
```

Permite ver qué ciudad vende más.

Preguntas

¿Qué año tuvo más ventas?

¿Qué ciudad vende más en 2025?

¿Para qué sirve agrupar datos (groupby)?

Ejercicio resuelto OLAP con Python

Solución 1 — Slice (Año 2025)

Código:

```
ventas_2025 = df[df["Año"] == 2025]
print(ventas_2025)
print("Total ventas 2025:", ventas_2025["Ventas"].sum())
```

Solución 2 — Dice (Vigo + Portátiles)

Código:

```
vigo_portatiles = df[(df["Ciudad"] == "Vigo") & (df["Producto"] == "Portátiles")]
print(vigo_portatiles)
```

Solución 3 — Roll-up (Ventas totales por año)

Código:

```
total_por_año = df.groupby("Año")["Ventas"].sum()
print(total_por_año)
```

3. *Dashboard/scorecard*

Dashboard y Scorecard como dos herramientas complementarias de monitorización y gestión del rendimiento.

1. Definición básica

Dashboard: interfaz visual que muestra métricas e indicadores operativos y tácticos, normalmente en (casi) tiempo real, para monitorizar la situación “aquí y ahora”.

Scorecard / Balanced Scorecard: herramienta de gestión que muestra objetivos estratégicos, indicadores asociados, valores objetivo (targets) y grado de cumplimiento en un periodo de tiempo.

En resumen: el dashboard se centra en “qué está pasando”, el scorecard en “qué tan bien vamos respecto a los objetivos”.

3. Dashboard/scorecard

Dashboard en sistemas de análisis de información

Características principales: Orientado a monitorización continua y decisiones operativas o tácticas. Integra múltiples fuentes de datos (ERP (Enterprise Resource Planning), CRM (Customer Relationship Management), web, etc.) y presenta KPIs claves en una sola pantalla.

Visualizaciones: gráficos de líneas, barras, mapas, indicadores tipo velocímetro, tarjetas de número clave, tablas, etc.

Trabaja mucho con datos detallados y series temporales, permitiendo filtrado, segmentación y “drill-down”.

Ejemplos de dashboards en BI:

Dashboard de ventas: ventas por región, producto, canal, cumplimiento sobre objetivo mensual.

Dashboard financiero: ingresos, gastos, EBITDA, flujo de caja, comparativa real vs presupuesto.

Dashboard de RRHH: rotación, absentismo, evaluaciones de desempeño, clima laboral.

Beneficios didácticos a destacar: visión rápida, detección temprana de problemas, soporte a la toma de decisiones basada en datos.

3. Dashboard/scorecard

Alphabet Inc.
CONSOLIDATED STATEMENTS OF INCOME
(in millions, except per share amounts)

	Year Ended December 31,		
	2021	2022	2023
Revenues Ingresos	$ 257,637	$ 282,836	$ 307,394
Costs and expenses: Costes y Gastos			
Cost of revenues Costes de ingresos	110,939	126,203	133,332
Research and development Gasto en I+D	31,562	39,500	45,427
Sales and marketing Gasto en Ventas y Marketing	22,912	26,567	27,917
General and administrative Gastos Generales y Administrativos	13,510	15,724	16,425
Total costs and expenses Suma Total Costes y Gastos	178,923	207,994	223,101
Income from operations Beneficio Operativo	78,714	74,842	84,293
Other income (expense), net Gastos ó Ingresos Financieros	12,020	(3,514)	1,424
Income before income taxes Beneficio antes de impuestos	90,734	71,328	85,717
Provision for income taxes Cantidad de Impuestos	14,701	11,356	11,922
Net income Beneficio Neto	$ 76,033	$ 59,972	$ 73,795
BPA con Acciones Básicas			
Basic net income per share of Class A, Class B, and Class C stock	$ 5.69	$ 4.59	$ 5.84
Diluted net income per share of Class A, Class B, and Class C stock	$ 5.61	$ 4.56	$ 5.80

Acciones Diluidas 2023 : 12.722 BPA con Acciones Diluidas

Actividad

Ejercicio: Cuenta de Resultados – Empresa *TechNova S.A.*

La empresa **TechNova S.A.**, dedicada al desarrollo de software empresarial, presenta la siguiente información financiera correspondiente a los años 2022 y 2023 (cantidades en millones de €).

Concepto	2022	2023
Ingresos	185.000	210.000
Costes de ingresos	82.000	95.000
Gasto en I+D	24.500	27.000
Gasto en Ventas y Marketing	18.200	20.500
Gastos Generales y Administrativos	10.300	11.200
Otros ingresos (gastos) financieros	-2.000	3.500
Impuestos	9.800	11.400

Actividad

1. Calcular el total de costes y gastos

Suma los siguientes conceptos:

Costes de ingresos

Gasto en I+D

Ventas y Marketing

Gastos Generales y Administrativos

Total costes y gastos = ?

2. Calcular el Beneficio Operativo

Utiliza la fórmula:

- $Beneficio\ Operativo = Ingresos - Total\ costes\ y\ gastos$

Calcula el resultado para:

Año 2022

Año 2023

3. Calcular el Beneficio antes de impuestos

- $Beneficio\ antes\ de\ impuestos = Beneficio\ operativo + Otros\ ingresos\ (o\ gastos)$

Recuerda:

Si el valor es negativo → resta.

Si es positivo → suma.

4. Calcular el Beneficio Neto

- $Beneficio\ Neto = Beneficio\ antes\ de\ impuestos - Impuestos$

5. Preguntas de análisis

Responde brevemente:

a) ¿Han aumentado los ingresos de la empresa?
b) ¿Qué tipo de gasto crece más entre 2022 y 2023?
c) ¿Los resultados financieros ayudan o perjudican en cada año?
d) ¿Mejora el beneficio neto en 2023? Explica por qué.

Actividad (solución)

(Cantidades en millones de €)

1. Total de costes y gastos

Año 2022

- $82.000 + 24.500 + 18.200 + 10.300 = 135.000$

Total costes y gastos 2022 = 135.000

Año 2023

- $95.000 + 27.000 + 20.500 + 11.200 = 153.700$

Total costes y gastos 2023 = 153.700

2. Beneficio Operativo

- $Beneficio\ Operativo = Ingresos - Total\ costes\ y\ gastos$

2022

- $185.000 - 135.000 = 50.000$

Beneficio operativo 2022 = 50.000

2023

- $210.000 - 153.700 = 56.300$

Beneficio operativo 2023 = 56.300

3. Beneficio antes de impuestos

- $Beneficio\ antes\ de\ impuestos = Beneficio\ operativo + Otros\ ingresos/gastos$

2022

- $50.000 + (-2.000) = 48.000$

Beneficio antes de impuestos 2022 = 48.000

2023

- $56.300 + 3.500 = 59.800$

Beneficio antes de impuestos 2023 = 59.800

4. Beneficio Neto

- $Beneficio\ Neto = Beneficio\ antes\ de\ impuestos - Impuestos$

2022

- $48.000 - 9.800 = 38.200$

Beneficio neto 2022 = 38.200

2023

- $59.800 - 11.400 = 48.400$

Beneficio neto 2023 = 48.400

Actividad (solución)

Concepto	2022	2023
Total costes y gastos	135.000	153.700
Beneficio operativo	50.000	56.300
Beneficio antes de impuestos	48.000	59.800
Beneficio neto	**38.200**	**48.400**

Actividad (solución)

5. Preguntas de análisis (respuestas orientativas)

a) ¿Han aumentado los ingresos?
Sí, pasan de 185.000 a 210.000.

b) ¿Qué gasto crece más?
Costes de ingresos (+13.000).

c) ¿Los resultados financieros ayudan o perjudican?

2022 → perjudican (−2.000).

2023 → ayudan (+3.500).

d) ¿Mejora el beneficio neto?
Sí, aumenta porque crecen los ingresos y además los ingresos financieros son positivos en 2023.

Actividad año 2025 de Google

Descarga el informe anual de Google de 2025 y crea una tabla similar a la que vimos sobre los años del 2021 al 2023 poniendo todos los gastos e ingresos.

El informe puede verse en https://abc.xyz/investor/sec-filings/default.aspx , el 10k.

El **Form 10-K** es el **informe anual completo** que una empresa cotizada debe presentar cada año. Es el documento más detallado sobre la compañía.

Incluye:

- Resultados financieros auditados del año completo.
- Descripción del negocio y estrategia.
- Principales riesgos.
- Información sobre directivos y gobierno corporativo.
- Análisis de la dirección (MD&A).
- Estados financieros revisados por auditores.

Se presenta **una vez al año** tras cerrar el ejercicio fiscal.

3. Dashboard/scorecard

Scorecard y Balanced Scorecard

Un **scorecard** muestra indicadores asociados a objetivos, comparando valor actual con valor objetivo y señalando el grado de cumplimiento (semáforos, colores, iconos de tendencia).

El **Balanced Scorecard (Cuadro de Mando Integral)** traduce la estrategia de la organización en objetivos medibles, organizados en perspectivas (financiera, clientes, procesos internos, aprendizaje y crecimiento), cada uno con indicadores y planes de acción.

Componentes típicos de un Balanced Scorecard:

Perspectivas: grandes ejes estratégicos (finanzas, clientes, procesos, innovación/personas).

Objetivos estratégicos: lo que se quiere lograr en cada perspectiva.

Indicadores (KPIs): cómo se mide cada objetivo.

Metas (targets) y umbrales: valor deseado y rangos de aceptación.

Iniciativas o acciones: proyectos ligados al cumplimiento de cada objetivo.

Un scorecard suele mostrar “instantáneas periódicas” (mensual, trimestral, anual) del desempeño frente a esos objetivos.

Ejercicio: Diseñando un Balanced Scorecard

Empresa *EcoMarket S.L.*

La empresa **EcoMarket S.L.** es una cadena de supermercados ecológicos que quiere mejorar su estrategia empresarial utilizando un **Cuadro de Mando Integral (Balanced Scorecard)**.

La dirección ha definido el siguiente objetivo general:

"Crecer de forma sostenible mejorando la satisfacción del cliente y la eficiencia interna."

Tu tarea será ayudar a la empresa a transformar esta estrategia en objetivos medibles.

1 — Identificar las perspectivas

Relaciona cada objetivo con la perspectiva correcta del Balanced Scorecard:

Perspectivas disponibles:

Financiera

Clientes

Procesos Internos

Aprendizaje y Crecimiento

Objetivos estratégicos

Aumentar los beneficios anuales.

Reducir el tiempo de reposición de productos en tienda.

Mejorar la formación digital de los empleados.

Incrementar la satisfacción del cliente.

Escribe qué perspectiva corresponde a cada objetivo.

Ejercicio: Diseñando un Balanced Scorecard (solución)

Nº	Objetivo estratégico	Perspectiva del Balanced Scorecard
1	Aumentar los beneficios anuales	**Financiera**
2	Reducir el tiempo de reposición de productos en tienda	**Procesos Internos**
3	Mejorar la formación digital de los empleados	**Aprendizaje y Crecimiento**
4	Incrementar la satisfacción del cliente	**Clientes**

4. Herramientas
4.1. Administración

Las **herramientas de Business Intelligence integran varias capas: almacenamiento (data warehouse/lakehouse), procesos ETL/ELT, motores OLAP, y herramientas de explotación (dashboards y scorecards)**. Sobre esta base se construyen soluciones con productos como Power BI, Tableau, Looker, Oracle BI, etc., que permiten análisis, visualización y distribución de la información.

4.1. Administración

La **administración** de un sistema de análisis de información abarca el ciclo de vida completo: planificación, implantación, operación y mejora continua del entorno de data warehouse y BI. Puede estructurarse en estos bloques:

Gestión de la plataforma y despliegue

- Instalación y configuración de todos los componentes: bases de datos del data warehouse, servidores OLAP, portales de BI, servicios ETL.
- Integración con el ecosistema corporativo: directorio de usuarios (p. ej. Active Directory), aplicaciones origen (ERP, CRM, aplicaciones internas), herramientas ofimáticas.
- Definición de la arquitectura lógica y física ajustada a necesidades de rendimiento, seguridad y disponibilidad.

4. Herramientas
4.1. Administración

Administración de datos y metadatos

Supervisar y mantener los procesos de carga de datos (ETL/ELT): programación, ejecución, control de tiempos y volúmenes.

Control de calidad y coherencia de datos: validaciones, reconciliaciones frente a sistemas origen, detección y corrección de errores.

Gestión de metadatos técnicos y de negocio (catálogo de tablas, cubos, KPIs, definiciones de indicadores) y controles de consistencia entre datos y metadatos.

Administración funcional de BI (dashboards y scorecards)

Alta, modificación y retirada de cuadros de mando, informes y modelos analíticos, alineados con las necesidades de negocio.

Gestión del catálogo de KPIs y objetivos: definición, periodicidad de actualización, responsables y documentación asociada.

Control de versiones y cambios en dashboards/scorecards (por ejemplo, incorporar nuevos indicadores o modificar umbrales de semáforos).

Seguridad, usuarios y uso

Gestión de usuarios, roles y permisos: quién puede ver qué datos, qué cuadros de mando y a qué nivel de detalle (seguridad por roles, por área, por jerarquía).

Auditoría y monitorización del uso: estadísticas de uso de informes, cubos y dashboards para optimizar recursos y priorizar mejoras.

Protección de la información sensible mediante políticas de acceso, enmascaramiento de datos y cumplimiento normativo (p. ej. datos personales).

4. Herramientas
4.1. Administración

Monitorización, rendimiento y mantenimiento

- Supervisar el rendimiento de consultas, procesos y aplicaciones (tiempos de respuesta, cargas, concurrencia).
- Ajuste y optimización: índices, agregaciones, particiones, restructuración de cubos y modelos para mejorar tiempos de respuesta.
- Gestión de errores e incidencias: detección temprana, corrección rápida y comunicación a usuarios cuando un proceso o informe falla.

Evolución y gobierno del sistema

- Planificación del crecimiento del data warehouse (nuevas fuentes, nuevos dominios de datos, nuevas necesidades de análisis).
- Definición de políticas de gobierno del dato (data governance): estándares, responsabilidades, procesos de aprobación de nuevos KPIs y cambios en los modelos.
- Actividades formativas y de comunicación para que usuarios y dirección aprovechen los dashboards y scorecards en la gestión diaria y estratégica.

Actividades

Realiza las tareas del documento 3. Crear tu primer repositorio en GitHub que encontrarás en la carpeta MÁS CONTENIDO.

Git y **GitHub** están relacionados, pero no son lo mismo:

- **Git**: es un **sistema de control de versiones** que permite guardar cambios en archivos, ver el historial y trabajar en equipo sin perder versiones anteriores del proyecto.
- **GitHub**: es una **plataforma online** que usa Git para almacenar proyectos en la nube y facilitar la colaboración entre personas.

Resumen rápido:
Git = herramienta para controlar cambios.
GitHub = web donde compartes y colaboras usando Git.

4.2. Migración

La **migración** es el proceso de trasladar datos, modelos y artefactos analíticos (cubos, dashboards, scorecards, informes) desde un sistema origen a un sistema destino, minimizando interrupciones y riesgos. Suele plantearse cuando la plataforma actual se queda obsoleta, se decide mover el data warehouse a la nube o se sustituye una herramienta de BI por otra más moderna.

Objetivos de la migración

Garantizar la **continuidad** del servicio analítico (que usuarios sigan disponiendo de sus informes y cuadros de mando). Mejorar capacidades: rendimiento, escalabilidad, funciones avanzadas (autoservicio, analítica avanzada, integración con nuevas fuentes). Reducir costes de infraestructura y mantenimiento, especialmente al migrar de on-premise a cloud.

Fases típicas de la migración

Evaluación del entorno actual

- Inventario de fuentes de datos, procesos ETL, modelos (esquemas estrella/cubos), informes, dashboards y scorecards existentes.
- Análisis de volúmenes, criticidad de cargas y calidad de datos.

Definición de objetivos y alcance

- Decidir qué se migra tal cual, qué se rediseña y qué se descataloga.
- Alinear la migración con objetivos de negocio: rapidez de consulta, autoservicio, nuevas analíticas, reducción de coste.

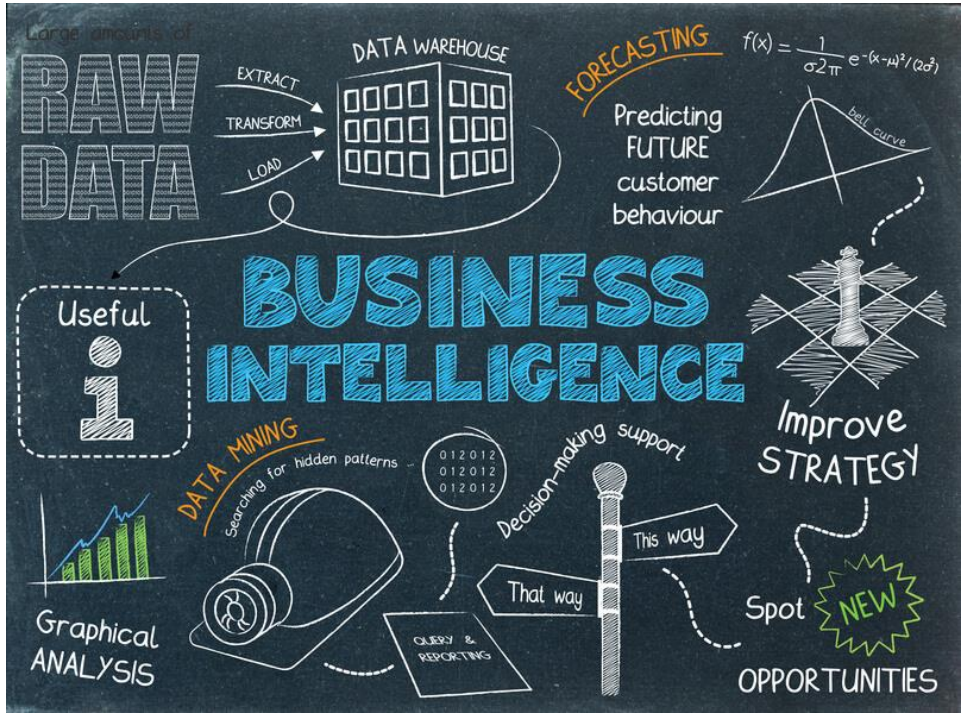

4.2. Migración

Selección de plataforma y estrategia de migración

Elegir plataforma destino (por ejemplo, data warehouse en la nube, nuevo motor OLAP, nueva herramienta de BI).

Estrategias habituales:

- **Lift-and-shift**: mover casi “tal cual” la solución actual al nuevo entorno, con cambios mínimos.
- **Replataformado**: adaptar procesos y modelos para aprovechar servicios nativos (almacenamiento escalable, ETL en la nube, etc.).
- **Rediseño/refactorización**: reconstruir el DWH/BI desde cero, optimizando modelo de datos y cuadros de mando.

Migración de datos y procesos

Diseño y ejecución de procesos de carga desde el sistema origen al destino (ETL/ELT específicos de migración).

Validación de integridad y reconciliación de datos (conteos, totales de negocio, puntos de control).

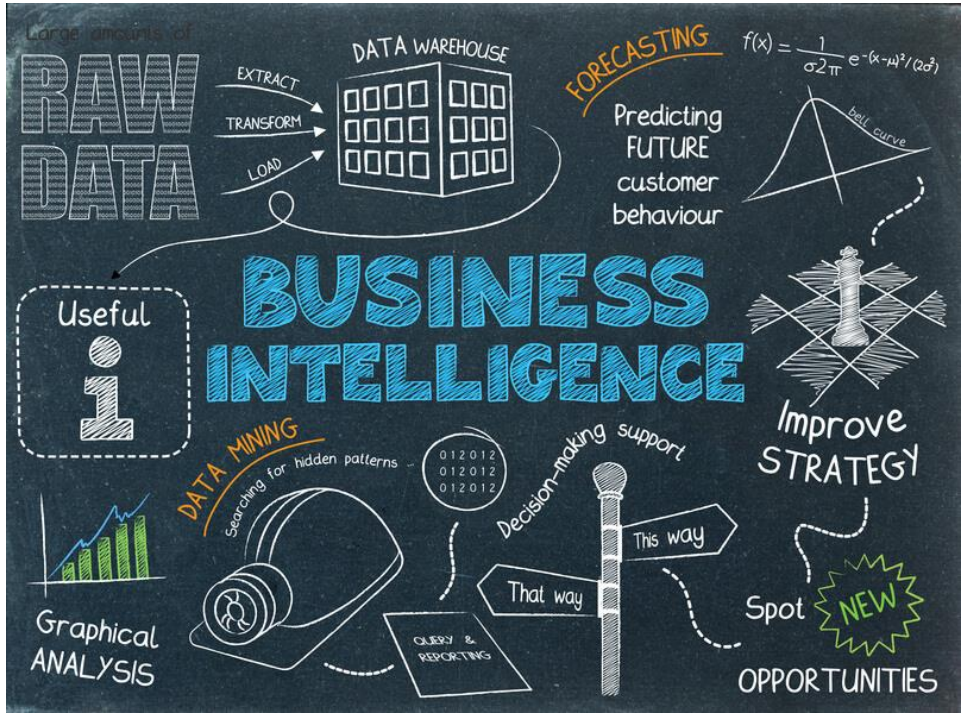

4.2. Migración

Migración de modelos y artefactos BI

Adaptación o recreación de modelos semánticos, cubos OLAP y vistas.

Conversión o rediseño de informes, dashboards y scorecards en la nueva herramienta, aprovechando nuevas capacidades.

Pruebas, ajuste y puesta en producción

Pruebas funcionales (que informes y KPIs calculen lo mismo) y de rendimiento.

Optimización (particionado, índices, agregaciones, tuning de consultas) y corrección de incidencias antes de la puesta en marcha definitiva.

Gestión del cambio y desmantelamiento del sistema antiguo

Formación a usuarios y TI sobre la nueva plataforma, nuevas formas de acceso y nuevas funciones.

Plan de coexistencia temporal (ambos sistemas activos) y posterior apagado controlado del entorno legado.

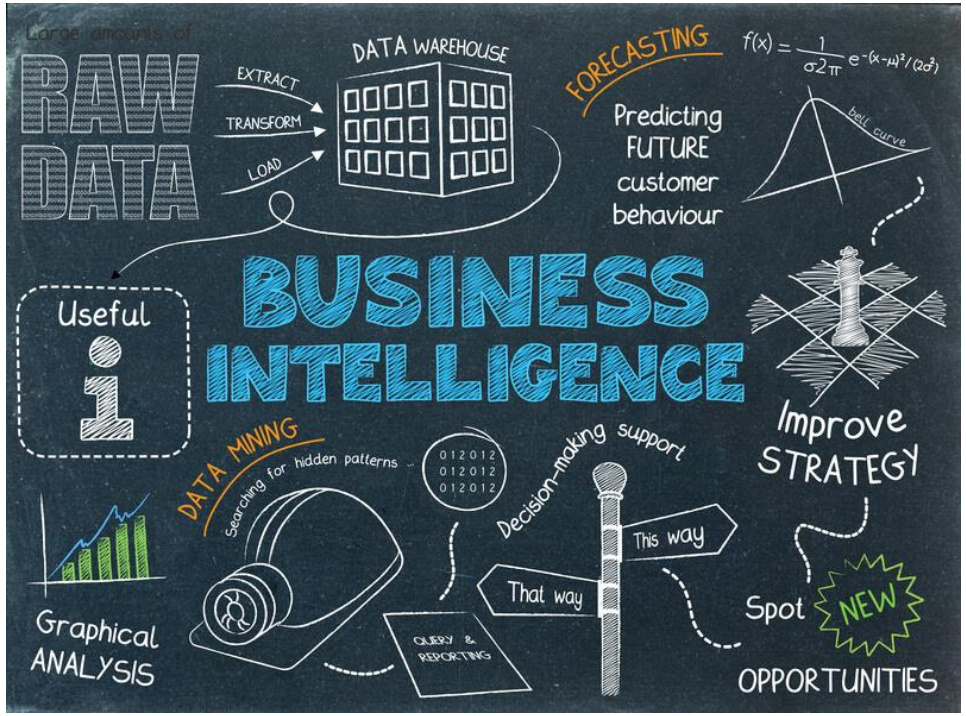

Actividades

Accede a Looker Studio (https://lookerstudio.google.com/u/0/navigation/reporting) y abre un documento con el que hayas trabajado. Revisa el control de versiones que tiene incorporado la aplicación y ponle un nombre a la versión actual como versión 1.0.

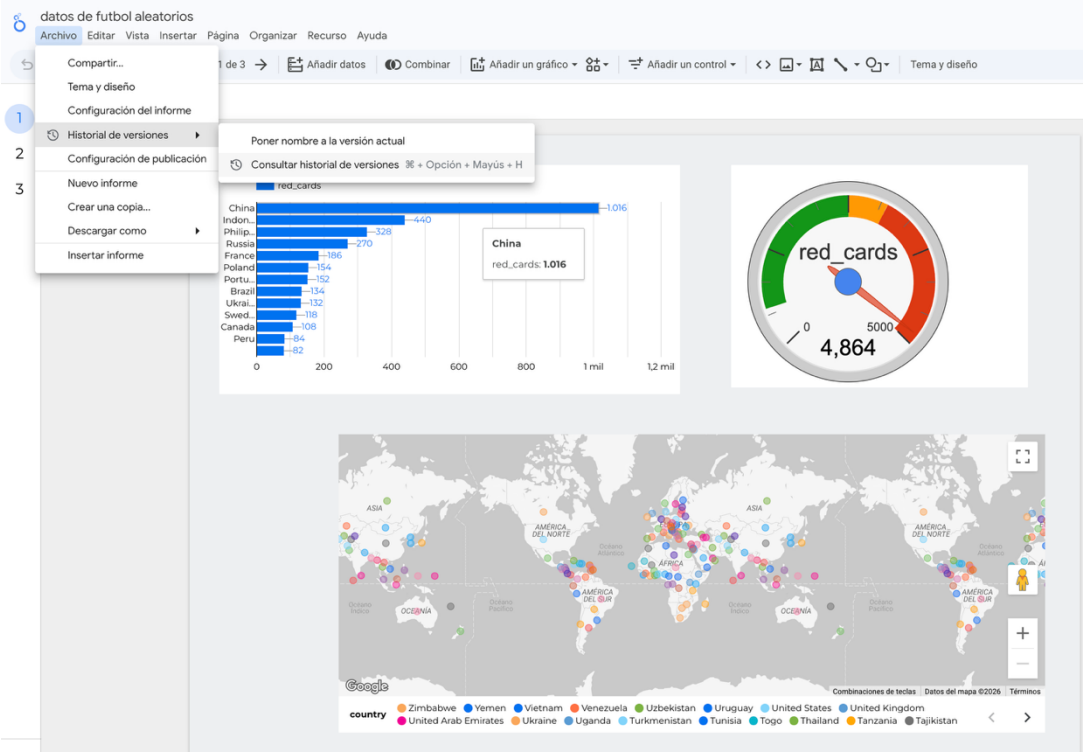

4.3. ETL

ETL son las siglas de **Extract, Transform, Load** (Extracción, Transformación y Carga). Es el proceso que integra datos de múltiples fuentes, los depura y los carga en un repositorio analítico (data warehouse, data mart, lakehouse) para poder explotarlos con BI.

En otros términos: es la "tubería" que lleva datos desde los sistemas operacionales (OLTP, ficheros, APIs, etc.) hasta el sistema de análisis (OLAP, dashboards, scorecards), asegurando calidad y coherencia.

Las tres fases: Extract, Transform, Load

1. Extracción (Extract)

Se identifican y conectan las **fuentes de datos**: bases relacionales (ERP, CRM), hojas de cálculo, ficheros planos, servicios web, etc.

Se extraen los datos relevantes (completos o incrementales) siguiendo una planificación (por lotes nocturnos, horarios, casi tiempo real).

Suele haber una **zona de staging** o área de preparación donde se depositan los datos sin apenas cambios.

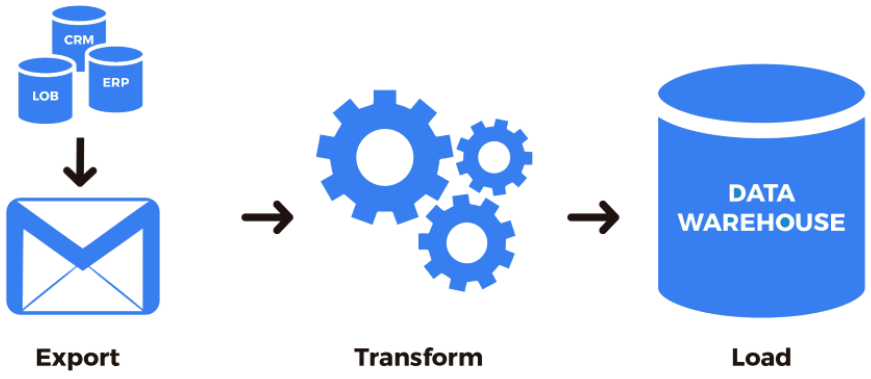

4.3. ETL

2. Transformación (Transform)

Es la fase más rica desde el punto de vista de modelado y calidad de datos:

Limpieza: tratamiento de nulos, duplicados, formatos incorrectos, valores fuera de rango.

Normalización y estandarización: unificar formatos de fechas, códigos de país, monedas, etc.

Integración de fuentes: combinar datos de distintos sistemas para construir entidades de negocio coherentes (cliente único, producto maestro, etc.).

Enriquecimiento: cálculos de campos derivados (márgenes, ratios, indicadores, claves sustitutas).

Aplicación de **reglas de negocio**: por ejemplo, cómo se agrupan productos, qué se considera cliente activo, cómo se maneja el histórico de cambios (SCD).

Adaptación al modelo objetivo (estrella, copo de nieve, modelo tabular).

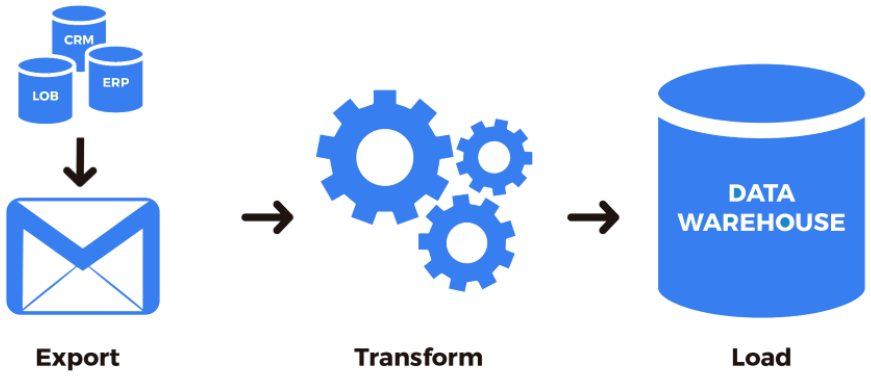

4.3. ETL

3. Carga (Load)

Se cargan los datos transformados en las **tablas de dimensiones y de hechos** de la data warehouse.

Puede ser:

- Carga inicial masiva (primer llenado histórico).
- Cargas incrementales (solo cambios desde la última ejecución).
- Cargas completas puntuales (reset de una tabla cuando procede).

Se actualizan también agregados, índices, particiones, y se disparan procesos posteriores (por ejemplo, procesamiento de cubos OLAP).

El sistema de análisis se apoya en:

- Fuentes OLTP.
- Procesos ETL.
- Data warehouse / data mart.
- OLAP + Dashboards + Scorecards.

ETL es lo que:

- Garantiza que los indicadores de un dashboard/scorecard se basen en datos limpios y consistentes.
- Permite consolidar información histórica y de múltiples aplicaciones en una visión única de la organización.

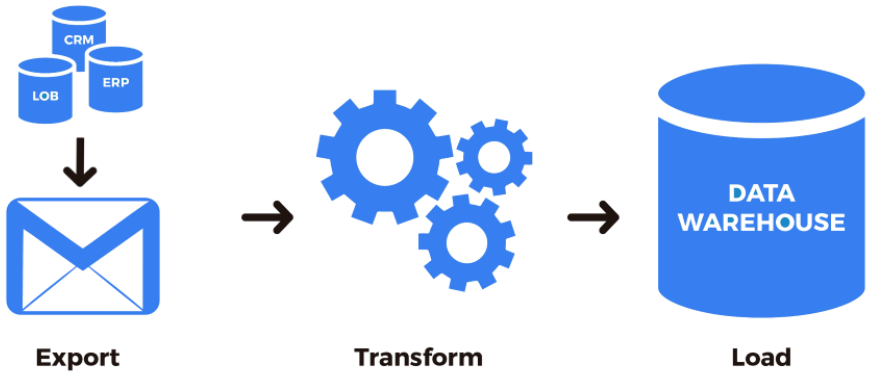

4.3. ETL

E — Extraer → coger datos.

T — Transformar → arreglar los datos.

L — Cargar → guardarlos para usarlos.

Ejemplo real:

Imagina una lista de teléfonos escrita así:

Ana - 666111222
ana - 666111222
Pedro -
MARIA - 777333444

Antes de usarla hay que:

quitar repetidos

completar datos

poner nombres iguales

Eso es **ETL**.

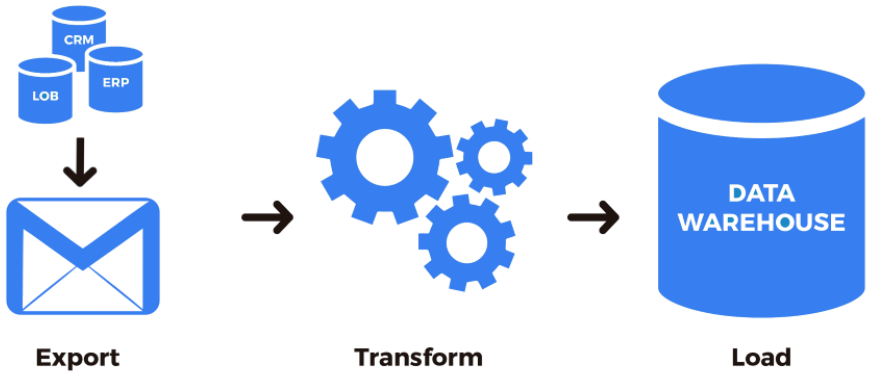

Actividad

¿Qué significa la letra E en ETL?

¿Qué hacemos en la fase Transformar?

¿Para qué sirve cargar los datos?

Escribe un ejemplo de datos que necesiten ordenarse.

4.4. Información estadística

el apartado de **información estadística** puede servir para conectar BI con conceptos básicos de análisis de datos.

1. Tipos de análisis estadístico

En la práctica de negocio se suelen distinguir varios tipos de análisis estadístico e/ó de datos:

Descriptivo: resume lo que ha pasado usando medias, medianas, frecuencias, porcentajes, tablas y gráficos; se usa para “describir” la realidad observada.

El análisis **descriptivo** se limita a resumir lo que ya ha ocurrido utilizando datos observados. Por ejemplo, una tienda online revisa sus ventas del mes pasado y calcula que vendió 10.000 euros, con una media diaria de 333 euros, y que el 45 % de los productos vendidos fueron camisetas. Con estos datos puede afirmar que las ventas fueron mayores los fines de semana y que las camisetas fueron el producto más popular. No intenta explicar causas ni hacer predicciones; simplemente describe la realidad.

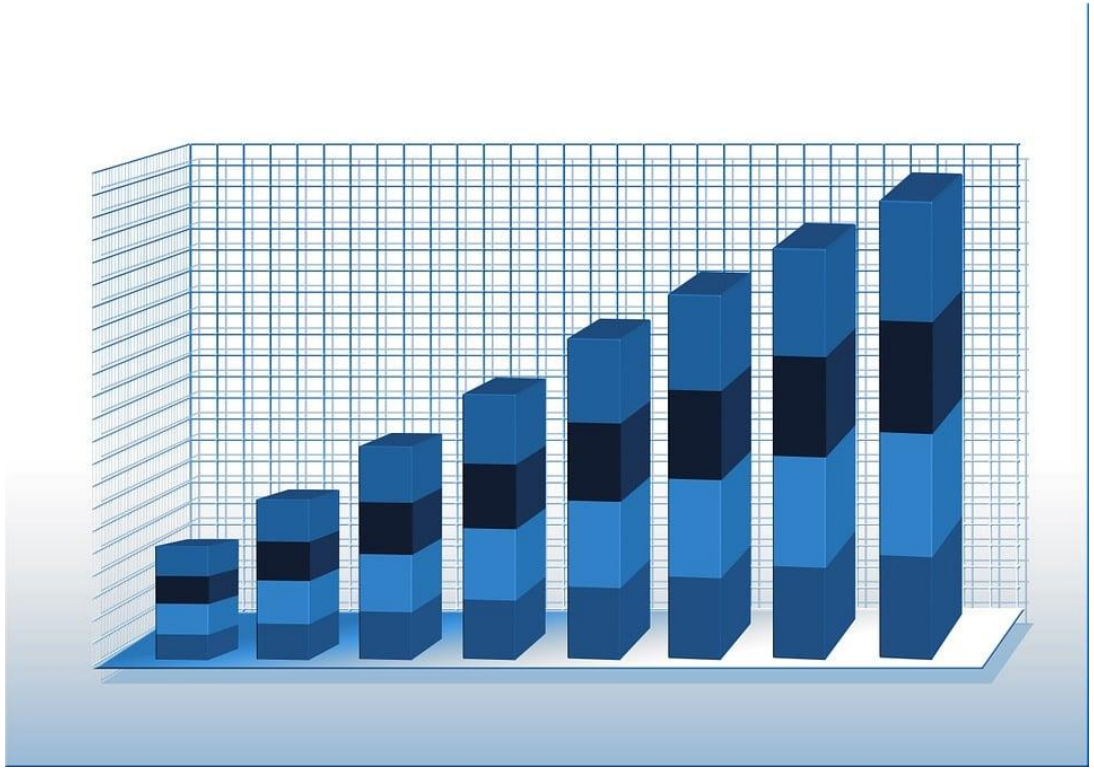

4.4. Información estadística

Inferencial: a partir de una muestra, hace estimaciones sobre una población (intervalos de confianza, pruebas de hipótesis), útil en encuestas, estudios de mercado, etc.

El análisis **inferencial** utiliza una parte de los datos, llamada muestra, para sacar conclusiones sobre un conjunto más grande, la población. Imaginemos que la tienda encuesta a 100 clientes de un total de 5.000 y observa que el 70 % está satisfecho. Aplicando técnicas estadísticas puede estimar que, probablemente, entre el 65 % y el 75 % de todos los clientes están satisfechos. No se ha preguntado a todos los clientes, pero se hace una estimación fiable a partir de una muestra.

Exploratorio: busca patrones, relaciones o anomalías sin hipótesis estricta previa; suele ser la primera fase para entender datos complejos.

El análisis **exploratorio** busca patrones o relaciones sin partir de una hipótesis estricta previa. El analista examina los datos de navegación y compra sin una idea concreta y descubre que los clientes que compran por la noche gastan más dinero y que quienes usan el móvil visitan más páginas, pero compran menos. Este tipo de análisis sirve para comprender mejor los datos y generar preguntas nuevas que después podrán estudiarse con más detalle.

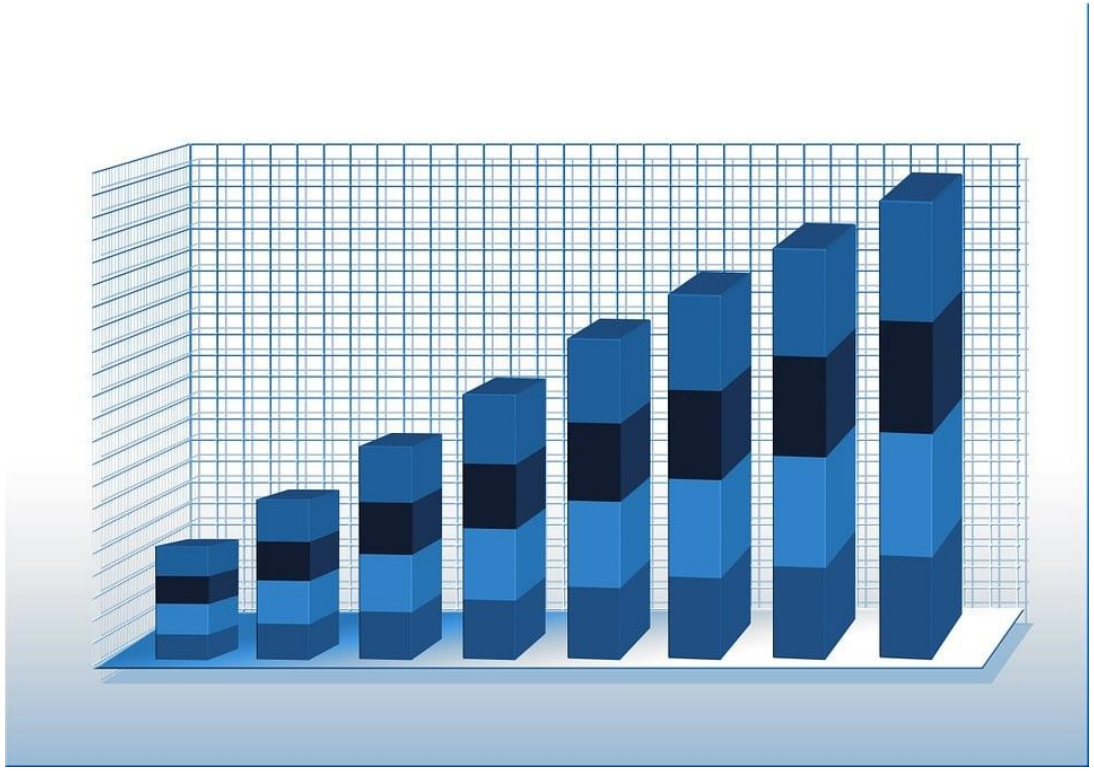

4.4. Información estadística

Predictivo: utiliza modelos y algoritmos (regresión, series temporales, modelos de clasificación) para prever comportamientos futuros a partir de datos históricos.

El análisis **predictivo** intenta anticipar lo que ocurrirá en el futuro utilizando datos históricos y modelos matemáticos. Si la tienda analiza las ventas de los últimos dos años mediante un modelo de regresión o una serie temporal, puede prever que el próximo mes alcanzará aproximadamente 12.000 euros en ventas y que habrá un aumento antes de Navidad. Aquí ya no se describe el pasado, sino que se estima un resultado futuro.

Prescriptivo: da un paso más y recomienda acciones concretas (qué hacer) combinando modelos predictivos con técnicas de optimización o simulación.

El análisis **prescriptivo** va un paso más allá del predictivo porque, además de prever resultados, recomienda acciones concretas. A partir de las predicciones y del análisis del stock, el sistema puede sugerir comprar más camisetas y lanzar promociones los viernes para maximizar beneficios. No solo dice qué ocurrirá, sino qué decisiones deberían tomarse para obtener un mejor resultado.

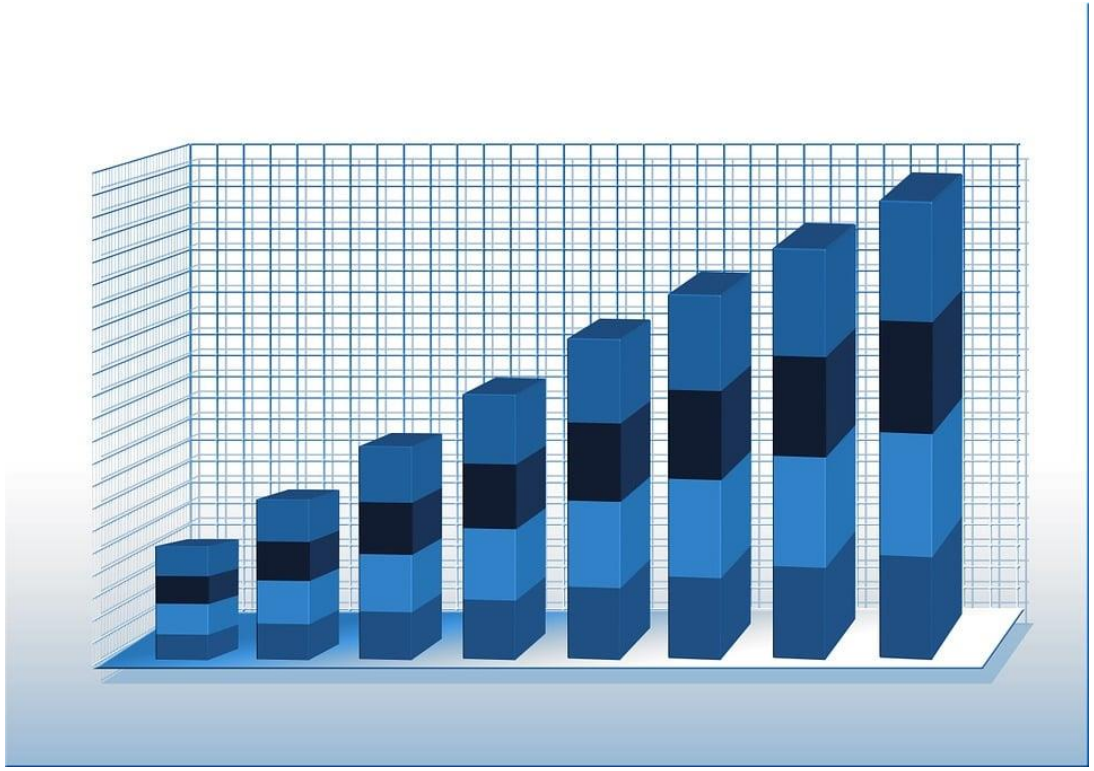

4.4. Información estadística

Causal / mecanicista: intenta establecer relaciones de causa-efecto o incluso el mecanismo detallado que une variables (más típico en ciencia que en reporting de negocio).

El análisis **causal o mecanicista** busca demostrar relaciones reales de causa y efecto. Por ejemplo, la tienda realiza un experimento ofreciendo envío gratis a un grupo de clientes mientras otro grupo mantiene las condiciones habituales. Si el grupo con envío gratis compra un 30 % más y el experimento está bien controlado, se puede concluir que el envío gratis provoca el aumento de ventas. Este enfoque intenta explicar por qué ocurre un fenómeno y cuál es el mecanismo que lo produce, algo muy común en investigación científica y experimentación.

En BI, tus dashboards tienden a ser sobre todo descriptivos y algo exploratorios; los modelos de datos y herramientas avanzadas soportan ya análisis predictivo/prescriptivo.

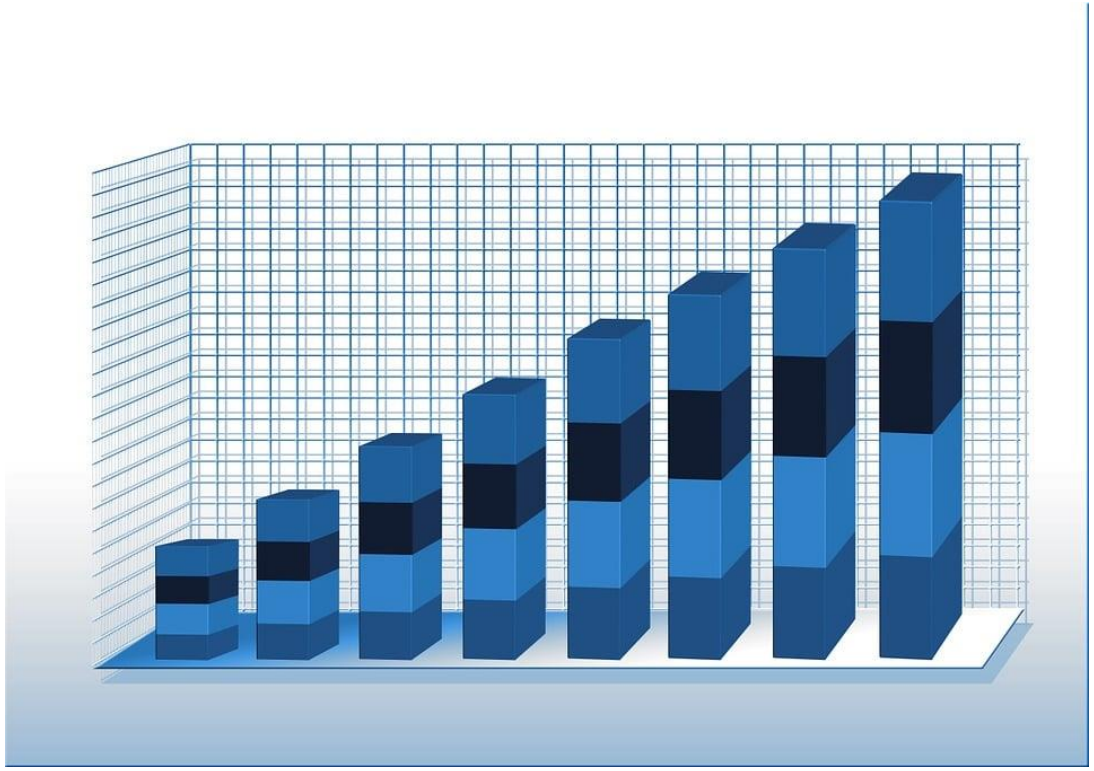

Actividad

Lee las siguientes situaciones y escribe qué tipo de análisis se está utilizando en cada caso: **descriptivo, inferencial, exploratorio, predictivo, prescriptivo o causal**.

- Una empresa analiza las ventas del último año y presenta un informe con medias mensuales, porcentajes de productos vendidos y gráficos comparativos entre meses.
- Un instituto encuesta a 120 estudiantes para estimar cuántos alumnos de todo el centro prefieren clases online y calcula un intervalo de confianza para el resultado.
- Un analista revisa un conjunto grande de datos sin hipótesis previa y descubre que los clientes jóvenes compran más por la noche y que ciertos productos suelen adquirirse juntos.
- Un supermercado utiliza datos históricos de ventas y un modelo estadístico para estimar cuántos productos venderá el próximo mes.
- Un sistema informático analiza la demanda futura y recomienda aumentar el stock de ciertos productos y reducir el precio de otros para mejorar los beneficios.
- Un investigador divide a los clientes en dos grupos, ofrece un descuento solo a uno de ellos y comprueba que ese grupo compra significativamente más, concluyendo que el descuento provoca el aumento de ventas.

Indica junto a cada situación el tipo de análisis correspondiente.

Actividad (solución)

La empresa analiza las ventas del último año y presenta un informe con medias mensuales, porcentajes de productos vendidos y gráficos comparativos entre meses.
Corresponde a un análisis **descriptivo**, porque resume y presenta lo que ya ha ocurrido sin hacer estimaciones ni predicciones.

El instituto encuesta a 120 estudiantes para estimar cuántos alumnos de todo el centro prefieren clases online y calcula un intervalo de confianza para el resultado.
Corresponde a un análisis **inferencial**, ya que utiliza una muestra para sacar conclusiones sobre toda la población.

Un analista revisa un conjunto grande de datos sin hipótesis previa y descubre que los clientes jóvenes compran más por la noche y que ciertos productos suelen adquirirse juntos.
Corresponde a un análisis **exploratorio**, porque busca patrones o relaciones sin una idea previa definida.

Un supermercado utiliza datos históricos de ventas y un modelo estadístico para estimar cuántos productos venderá el próximo mes.
Corresponde a un análisis **predictivo**, ya que intenta prever resultados futuros a partir de datos pasados.

Un sistema informático analiza la demanda futura y recomienda aumentar el stock de ciertos productos y reducir el precio de otros para mejorar los beneficios.
Corresponde a un análisis **prescriptivo**, porque además de predecir propone acciones concretas.

Un investigador divide a los clientes en dos grupos, ofrece un descuento solo a uno de ellos y comprueba que ese grupo compra significativamente más, concluyendo que el descuento provoca el aumento de ventas.
Corresponde a un análisis **causal**, porque demuestra una relación de causa-efecto mediante un experimento.

4.4. Información estadística

2. Tipos de datos estadísticos

Para explicar qué se analiza, puedes introducir la clasificación clásica de tipos de datos, que condiciona qué gráficos y qué técnicas estadísticas se pueden usar:

Cualitativos (categorías)

- Nominales: categorías sin orden (color, país, canal de venta).
- Ordinales: categorías con orden (niveles de satisfacción, rangos de prioridad).

Cuantitativos (numéricos)

- Discretos: toman valores aislados contables (número de ventas, número de reclamaciones).
- Continuos: pueden tomar cualquier valor en un intervalo (importe de venta, tiempo de respuesta, temperatura).

En un dashboard, por ejemplo, “país” o “segmento de cliente” son variables cualitativas, mientras “importe de ventas” o “unidades vendidas” son cuantitativas.

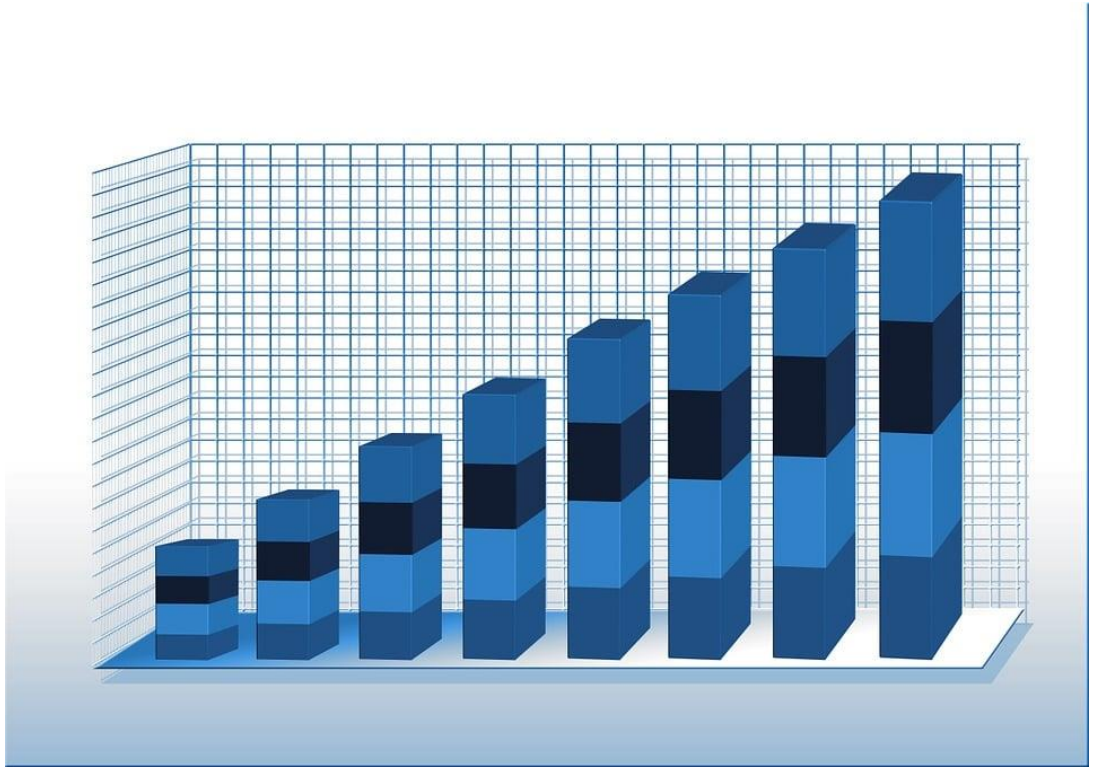

4.4. Información estadística

3. Relación con dashboards y scorecards

Los **dashboards** suelen mostrar análisis descriptivo y en parte exploratorio: distribuciones, tendencias, comparaciones entre categorías, etc.; el tipo de dato determina si usas barras, líneas, mapas, cajas y bigotes, etc.

Los **scorecards** usan fundamentalmente indicadores cuantitativos (KPIs) agregados y, a veces, resultados de análisis inferencial o predictivo traducidos a semáforos o niveles de cumplimiento de objetivos.

La calidad del sistema de análisis no sólo depende de la tecnología (DWH, OLAP, ETL), sino también de un uso adecuado de la información estadística: tipos de datos, tipos de análisis y elección de indicadores apropiados para la toma de decisiones.

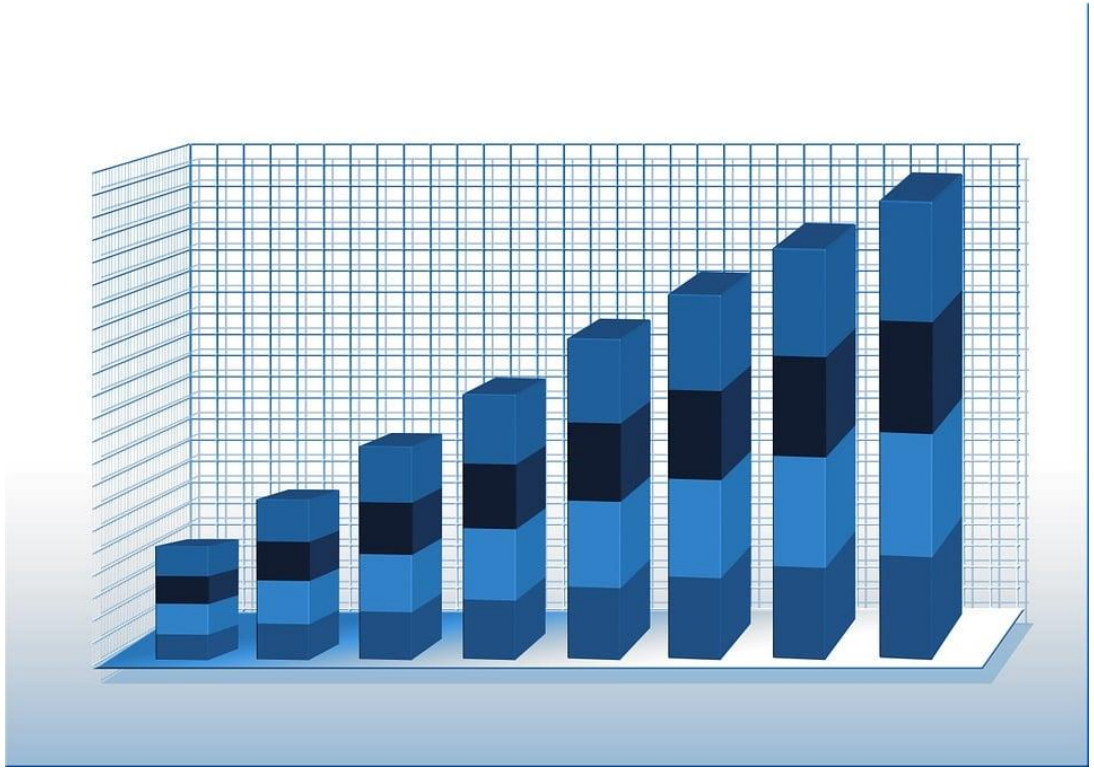

Fin de la presentación